

**PONTIFÍCIA UNIVERSIDADE CATÓLICA DE SÃO PAULO**

**FACULDADE DE CIÊNCIAS EXATAS E TECNOLOGIA**

**CIÊNCIA DA COMPUTAÇÃO**



**PUC-SP**

**LEONARDO FAJARDO GRUPIONI**

**Detecção de Garimpo Ilegal na Amazônia com Visão Computacional e Redes Neurais  
Convolucionais**

**SÃO PAULO**

**2025**

**Leonardo Fajardo Grupioni**

**Detecção de Garimpo Ilegal na Amazônia com Visão Computacional e Redes Neurais  
Convolucionais**

Trabalho de Conclusão de Curso  
apresentado à Banca Examinadora da  
Pontifícia Universidade Católica de São  
Paulo, como um dos requisitos para a  
conclusão do Curso de Bacharelado em  
Ciência da Computação, sob orientação  
da Profa. Dra. Edith Ranzini.

**SÃO PAULO**

**2025**

## AGRADECIMENTOS

À minha orientadora, Profa. Dra. Edith Ranzini, agradeço pelo apoio inestimável e pela inspiração ao longo de toda a graduação, e, especialmente, pela condução segura e atenta no desenvolvimento deste trabalho.

Ao Prof. Dr. Felipe Valencia Almeida, da Escola Politécnica da USP, expresso minha gratidão pela coorientação realizada informalmente durante este ano. Suas contribuições foram essenciais para o amadurecimento desta pesquisa e para os meus próximos passos acadêmicos.

Agradeço também ao geógrafo Thomaz Gallois, especialista em sensoriamento remoto, pelas ideias fundamentais para a concepção deste projeto e por todo o suporte técnico oferecido.

Por fim, agradeço aos meus familiares e amigos, que me apoiaram durante toda a jornada da graduação. Obrigado por estarem ao meu lado nos momentos mais desafiadores e por celebrarem comigo cada conquista!

*“No começo pensei que estivesse lutando para salvar seringueiras,  
depois pensei que estava lutando para salvar a Floresta Amazônica.*

*Agora, percebo que estou lutando pela humanidade.”*

**(Chico Mendes)**

## RESUMO

O avanço do garimpo ilegal na Amazônia brasileira configura uma das principais ameaças à biodiversidade e às comunidades locais, exigindo mecanismos de monitoramento ágeis e escaláveis. Este trabalho propõe o desenvolvimento de um modelo de visão computacional baseado em Redes Neurais Convolucionais (CNNs) para a detecção automática de frentes de mineração em imagens de satélite. A metodologia utilizou a plataforma Google Earth Engine para a coleta e pré-processamento de dados, resultando na construção de um dataset balanceado com mais de 111 mil recortes de imagem, devidamente rotulados e curados para mitigar a interferência de nuvens. Para validar a abordagem, estabeleceu-se primeiramente um *baseline* com o algoritmo *Random Forest*, que atingiu um teto de acurácia de 72% e Área Sob a Curva (AUC) de 0,80, evidenciando as limitações de métodos baseados apenas em estatísticas de pixel. Em contrapartida, a implementação da arquitetura EfficientNet-B0, aliada a técnicas de Transferência de Aprendizado e *Fine-Tuning*, superou significativamente os modelos tradicionais, alcançando uma acurácia de 85,92% e uma AUC de 0,9371. Os resultados demonstram que o Aprendizado Profundo é capaz de extrair características espaciais complexas, distinguindo efetivamente cicatrizes de garimpo de outros alvos visuais ambíguos. Como contribuição à comunidade científica e ao suporte à fiscalização, todo o código-fonte desenvolvido e a metodologia de criação do conjunto de dados foram disponibilizados em repositório aberto, fomentando a reproduzibilidade e a continuidade das pesquisas no monitoramento do bioma amazônico.

**Palavras-chave:** Visão Computacional; Garimpo Ilegal; Amazônia; Aprendizado Profundo; Sensoriamento Remoto; EfficientNet.

## ABSTRACT

The expansion of illegal mining in the Brazilian Amazon poses a major threat to biodiversity and local communities, demanding agile and scalable monitoring mechanisms. This work proposes the development of a computer vision model based on Convolutional Neural Networks (CNNs) for the automatic detection of mining fronts using satellite imagery. The methodology employed the Google Earth Engine platform for data collection and pre-processing, resulting in a balanced dataset containing over 111,000 image chips, labeled and curated to mitigate cloud interference. To validate the approach, a baseline was established using the Random Forest algorithm, which reached an accuracy ceiling of 72% and an Area Under the Curve (AUC) of 0.80, highlighting the limitations of pixel-based statistical methods. In contrast, the implementation of the EfficientNet-B0 architecture, combined with Transfer Learning and Fine-Tuning techniques, significantly outperformed traditional models, achieving an accuracy of 85.92% and an AUC of 0.9371. The results demonstrate that Deep Learning can effectively extract complex spatial features, distinguishing mining scars from other ambiguous visual targets. As a contribution to the scientific community and environmental enforcement efforts, the entire source code and the dataset creation methodology have been made available in an open repository, promoting reproducibility and further research on Amazon biome monitoring.

**Keywords:** Computer Vision; Illegal Mining; Amazon; Deep Learning; Remote Sensing; EfficientNet.

## LISTA DE FIGURAS

Figura 1 – Imagem de garimpo ilegal na Terra Indígena Kayapó.....	16
Figura 2 – Arquitetura de uma CNN para Detecção de Impactos Ambientais Multiclasse.....	22
Figura 3 – Hierarquia de representações em uma CNN (entrada, feature maps e saída).....	24
Figura 4 – Região selecionada da área de estudo com sobreposição do shapefile de mineração.....	33
Figura 5 – Região selecionada da área de estudo com sobreposição do shapefile de mineração ampliada.....	33
Figura 6 – Região selecionada da área de estudo com sobreposição dos recortes de chips.....	35
Figura 7 – Região selecionada da área de estudo com sobreposição do shapefile de mineração e recorte dos chips.....	36
Figura 8 – Gráfico de Distribuição do Brilho Médio.....	38
Figura 9 – Gráfico de Separabilidade do Brilho Médio.....	38
Figura 10 – Gráfico de Distribuição do Índice de Vegetação (ExG).....	39
Figura 11 – Gráfico de Separabilidade do Índice de Vegetação (ExG).....	40
Figura 12 – Gráfico de Distribuição da Variância (Nitidez).....	41
Figura 13 – Gráfico de Separabilidade da Variância (Nitidez).....	41
Figura 14 – Gráfico de Distribuição da Energia de Borda (Sobel).....	42
Figura 15 – Gráfico de Separabilidade da Energia de Borda (Sobel).....	43
Figura 16 – Gráfico de Barras da Distribuição de Densidade de Garimpo no Dataset.....	44
Figura 17 – Matrizes de Confusão da Regressão Logística e do Random Forest no Baseline.....	46
Figura 18 – Gráfico da Curva ROC e Curva Precision-Recall da Baseline.....	48
Figura 19 – Gráfico de Importância das Variáveis na Classificação com Random Forest.....	49
Figura 20 – Diagrama da Arquitetura da Simple CNN.....	52
Figura 21 – Diagrama da EfficientNet-B0 via Transfer Learning.....	53
Figura 22 – Gráficos de Histórico de Acurácia e Loss.....	53
Figura 23 – Matriz de Confusão da Simple CNN sobre o Conjunto de Testes.....	55
Figura 24 – Matriz de Confusão da EfficientNet-B0 (Fine-Tuned) sobre o Conjunto de Testes.....	56
Figura 25 – Gráfico das Curvas ROC Comparativas entre os modelos Simple CNN e EfficientNet-B0 (Fine-Tuned).....	57

## LISTA DE TABELAS

Tabela 1 – Comparação entre os modelos observados na revisão bibliográfica aos trabalhos relacionados.....	27
Tabela 2 – Quantidade de imagens do conjunto de treino e teste considerando as classes com garimpo e sem garimpo.....	37
Tabela 3 – Métricas dos algoritmos de Regressão Logística e Random Forest na Baseline.....	46
Tabela 4 – Métricas dos algoritmos de CNN: Simple CNN e EfficientNet-B0 (Fine-Tuned).....	56

## LISTA DE ABREVIATURAS E SIGLAS

ACC	<i>Accuracy</i>
AUC-PR	<i>Área sob a Curva Precisão-Revocação</i>
CBERS	<i>China–Brazil Earth Resources Satellite</i>
CNN	<i>Convolutional Neural Network</i>
ESA	<i>European Space Agency</i>
ExG	<i>Excess of Green</i>
Fmask	<i>Function of mask</i>
GAN	<i>Generative Adversarial Network</i>
GEE	<i>Google Earth Engine</i>
GEOBIA	<i>Geographic Object-Based Image Analysis</i>
Grad-CAM	<i>Gradient-weighted Class Activation Mapping</i>
HLS	<i>Harmonized Landsat–Sentinel</i>
INPE	<i>Instituto Nacional de Pesquisas Espaciais</i>
ISS	<i>International Space Station</i>
KNN	<i>K-Nearest Neighbors</i>
LiDAR	<i>Light Detection and Ranging</i>
LIME	<i>Local Interpretable Model-agnostic Explanations</i>
ML	<i>Machine Learning</i>
MODIS	<i>Moderate Resolution Imaging Spectroradiometer</i>
MPF	<i>Ministério Público Federal</i>
NASA	<i>National Aeronautics and Space Administration</i>
NDVI	<i>Normalized Difference Vegetation Index</i>
NDWI	<i>Normalized Difference Water Index</i>
NIR	<i>Near-Infrared</i>
PNG	<i>Portable Network Graphics</i>
RAISG	<i>Rede Amazônica de Informação Socioambiental Georreferenciada</i>
RF	<i>Random Forest</i>
RGB	<i>Red, Green, Blue</i>
SAR	<i>Synthetic Aperture Radar</i>
SVM	<i>Support Vector Machine</i>
SWIR	<i>Short-Wave Infrared</i>
USGS	<i>United States Geological Survey</i>

VIIRS      *Visible Infrared Imaging Radiometer Suite*  
XAI        *Explainable AI*

## SUMÁRIO

<b>1. INTRODUÇÃO.....</b>	<b>12</b>
1.1 Objetivo.....	12
1.2 Objetivos específicos.....	13
1.3 Motivação.....	13
1.4 Organização do Trabalho.....	14
<b>2. FUNDAMENTAÇÃO TEÓRICA.....</b>	<b>14</b>
2.1 Garimpo ilegal na Amazônia: impactos e desafios.....	15
2.2 Sensoriamento remoto na Amazônia.....	18
2.3 Características espectrais do garimpo ilegal.....	19
2.4 Pré-processamento de imagens no Google Earth Engine (GEE).....	20
2.5 Visão computacional e aprendizado de máquina em sensoriamento remoto.....	21
2.6 Redes Neurais Convolucionais (CNNs).....	23
2.7 Trabalhos relacionados.....	25
<b>3. METODOLOGIA.....</b>	<b>29</b>
<b>4. DESENVOLVIMENTO, RESULTADOS E DISCUSSÃO.....</b>	<b>32</b>
4.1 Coleta de dados.....	32
4.2 Construção do Dataset.....	34
4.3 Análise Exploratória de Dados (EDA).....	37
4.4 Avaliação de Baseline com Algoritmos Clássicos de Aprendizado de Máquina.....	44
4.4.1 Matrizes de Confusão e Métricas.....	45
4.4.2 Curvas de Desempenho (ROC e Precision-Recall).....	47
4.4.3 Importância das Variáveis.....	48
4.4.4 Limitações do Baseline e Justificativa para Aprendizado Profundo.....	49
4.5 Detecção de Garimpo com Redes Neurais Convolucionais (CNNs).....	50
4.5.1 Configuração Experimental e Pré-Processamento.....	51
4.5.2 Arquiteturas Avaliadas.....	51
4.5.3 Dinâmica de Treinamento e Convergência.....	53
4.5.4 Avaliação de Desempenho e Comparação Final.....	54
4.6 Reprodutibilidade e Disponibilização de Recursos.....	57
<b>5. CONCLUSÃO.....</b>	<b>59</b>
5.1 Trabalhos Futuros.....	60
<b>REFERÊNCIAS.....</b>	<b>61</b>

## 1. INTRODUÇÃO

O avanço do garimpo ilegal na Amazônia brasileira configura-se como uma das principais ameaças socioambientais e econômicas da região. Essa prática predatória provoca perdas florestais, degrada a qualidade da água, contamina solos com mercúrio e afeta diretamente a saúde e o modo de vida de populações indígenas e ribeirinhas. Segundo dados do MapBiomas, mais de 92% da área minerada no Brasil em 2022 concentrou-se na Amazônia, com aumento de aproximadamente 35 mil hectares em um único ano (MAPBIOMAS, 2025 a). A Rede Amazônica de Informação Socioambiental Georreferenciada (RAISG) mapeou 4.472 frentes de mineração ilegal em atividade, muitas delas sobrepostas a Terras Indígenas e Unidades de Conservação (RAISG, 2025).

A preocupação ganhou dimensão internacional. Em agosto de 2019, o secretário-geral da ONU, António Guterres, afirmou estar “profundamente preocupado” com os incêndios e defendeu que “a Amazônia precisa ser protegida”, reforçando a urgência de conter atividades ilícitas que agravam a crise climática no mundo (GUTERRES, 2019). No Brasil, sistemas de alerta como o DETER, do Instituto Nacional de Pesquisas Espaciais, detectam desmatamento quase em tempo real (INPE, 2024), entretanto, a identificação específica de frentes de garimpo ainda depende de inspeções presenciais ou análises visuais esporádicas de imagens de alta resolução por especialistas, o que limita a escala, a frequência e a reproduzibilidade.

Assim, técnicas de Visão Computacional associadas a Redes Neurais oferecem meios de automatizar e acelerar a detecção de padrões espectrais característicos do garimpo, como clareiras irregulares e sedimentos em suspensão nos cursos d’água. Com isso, modelos de aprendizado profundo treinados com grandes volumes de imagens multiespectrais podem alcançar alta sensibilidade, reduzir falsos positivos e fornecer mapas de probabilidade que facilitem o direcionamento de ações de fiscalização.

### 1.1 Objetivo

Frente ao cenário descrito, este trabalho tem por objetivo desenvolver e avaliar um modelo de Visão Computacional baseado em Redes Neurais Convolucionais (CNNs) capaz de identificar regiões de garimpo ilegal na Amazônia utilizando imagens de satélite multiespectrais e dados georreferenciados. Espera-se então que a abordagem proposta ofereça resultados reproduzíveis, acessíveis e úteis para pesquisadores, órgãos de fiscalização e formuladores de políticas públicas.

## 1.2 Objetivos específicos

Como objetivos específicos, destacam-se:

1. Coletar e preparar um dataset balanceado de áreas com e sem garimpo por meio do Google Earth Engine (GEE), integrando coleções Sentinel-2, máscaras de uso do solo do MapBiomas e polígonos da RAISG.
2. Projetar, treinar e otimizar um modelo de aprendizado profundo com Redes Neurais Convolucionais comparando com outros modelos de aprendizado de máquina.
3. Avaliar o desempenho do sistema por meio de métricas como acurácia, precisão, revocação, F1-score e Área Sob a Curva (AUC).
4. Disponibilizar os códigos e modelos treinados em repositório público, favorecendo a transparência e fomentando a reproduzibilidade acadêmica.

## 1.3 Motivação

A motivação para este trabalho surge da urgência em responder à crescente degradação ambiental na Amazônia, onde a mineração ilegal avança de maneira descontrolada, muitas vezes sobrepondo-se a áreas protegidas e territórios indígenas (RAISG, 2025; MAPBIOMAS, 2025a). Embora existam sistemas de monitoramento consolidados para o desmatamento, como o DETER (INPE, 2024), a identificação de novas frentes de garimpo ainda enfrenta gargalos técnicos significativos. A dinâmica dessa atividade é rápida e muitas vezes ocorre em regiões remotas, o que torna a fiscalização presencial ou a análise visual de imagens de satélite tarefas lentas e limitadas pela capacidade humana.

Deste modo, a Ciência da Computação oferece métodos capazes de transformar a análise de grandes volumes de dados ambientais. Com a disponibilidade de imagens de satélite gratuitas com alta frequência de revisita, aliada ao poder de processamento em nuvem e à capacidade de generalização das Redes Neurais, cria-se uma oportunidade única de investigação científica (RODRIGUES, 2024; CAMALAN et al., 2022). É possível explorar a detecção automática de padrões visuais complexos, como a turbidez da água e a textura de solo exposto, que caracterizam o garimpo.

Portanto, este estudo é motivado pela necessidade de avaliar o potencial de algoritmos de aprendizado profundo como uma solução de baixo custo e alta escalabilidade. Ao investigar metodologias que reduzam a dependência de análises manuais, busca-se contribuir

com um modelo que possa servir de base para futuros sistemas de suporte à decisão, permitindo que as ações de fiscalização sejam mais assertivas e baseadas em dados concretos.

## 1.4 Organização do Trabalho

A presente monografia está estruturada em cinco capítulos, dispostos da seguinte forma:

- **Capítulo 1 – Introdução:** Apresenta a contextualização do problema do garimpo ilegal na Amazônia, a motivação para o desenvolvimento da pesquisa e define os objetivos gerais e específicos a serem alcançados.
- **Capítulo 2 – Fundamentação Teórica:** Reúne o embasamento conceitual necessário, abrangendo o contexto histórico e ambiental da mineração na Amazônia, os princípios de sensoriamento remoto e uso do Google Earth Engine, os fundamentos das Redes Neurais Convolucionais e a revisão de trabalhos relacionados.
- **Capítulo 3 – Metodologia:** Descreve o percurso técnico adotado, detalhando desde as etapas de coleta e pré-processamento das imagens com construção do dataset até a estratégia de treinamento dos modelos e a publicação dos códigos em repositório aberto.
- **Capítulo 4 – Resultados e Discussão:** Exibe os dados obtidos com os experimentos, analisando as métricas de desempenho dos modelos desenvolvidos e discutindo a eficácia da abordagem proposta frente aos desafios identificados.
- **Capítulo 5 – Conclusão:** Sintetiza as principais contribuições da pesquisa, aponta as limitações encontradas durante o desenvolvimento e sugere direcionamentos para trabalhos futuros.

## 2. FUNDAMENTAÇÃO TEÓRICA

Nesta seção, constrói-se a fundamentação teórica necessária para sustentar o desenvolvimento desta pesquisa, detalhando os principais conceitos envolvidos. A discussão estende-se à análise de obras relacionadas, essenciais para situar e fundamentar a proposta metodológica escolhida.

### 2.1 Garimpo ilegal na Amazônia: impactos e desafios

A sequência histórica do MapBiomass revela que o garimpo artesanal avançou com rapidez nas últimas duas décadas. Em 2018 a atividade já ocupava 96 000 ha e, em 2020, alcançou 107 800 ha, ultrapassando a área total da mineração industrial no País (MOLINA, 2023; MAPBIOMAS, 2025b). A Coleção 7 confirma o ritmo ascendente, em 2022 o garimpo superou 120 000 ha, com forte concentração nas Terras Indígenas Kayapó (11 542 ha), Munduruku (4 744 ha) e Yanomami (1 557 ha). O dossiê *Amazon Underworld* contou cerca de 4 500 frentes ativas em toda a Pan-Amazônia em 2020, muitas sob controle de facções criminosas brasileiras ou estrangeiras (GLOBAL INITIATIVE, 2023). A Figura 1 ilustra o padrão típico do garimpo, com clareiras expostas e corpos d'água turvos.

Figura 1 – Imagem de garimpo ilegal na Terra Indígena Kayapó



Fonte: Molina (2023, p. 50)

Vários fatores explicam esse crescimento. O ouro ganhou destaque como reserva de valor em períodos de instabilidade, a legislação minerária apresenta lacunas, a mecanização barateou dragas e retro-escavadeiras, e a capacidade de fiscalização ambiental diminuiu (MOLINA, 2023). O resultado disso combina pressão econômica, tecnologia acessível e baixa percepção de risco.

Os efeitos ecológicos aparecem logo no primeiro ciclo de exploração. A extração aluvial utiliza, em média, 5 g de mercúrio por grama de ouro e pode chegar a 8 g (MOLINA, 2023). A contaminação espalha-se pelos cursos d’água em plumas que percorrem dezenas de quilômetros. Inclusive, um estudo pericial conduzido pelo Ministério PÚBLICO Federal estima que a produção de um quilograma de ouro em cavas profundas remove cerca de 111 ha de floresta, enquanto uma cava rasa de apenas 2,5 m já elimina quase 7 ha (MINISTÉRIO PÚBLICO FEDERAL, 2020). Além de suprimir vegetação e comprometer a qualidade da água, o processo libera carbono e facilita a abertura de novas frentes.

Com máquinas mais potentes, o garimpo tornou-se atividade de capital intensivo. Ele se organiza em uma hierarquia que reúne financiadores, pilotos de aeronaves e redes logísticas. Entre 2016 e 2022 a área garimpada em Terras Indígenas aumentou mais de oito

vezes, povos Kayapó, Munduruku e Yanomami convivem com índices de mercúrio que, no caso Munduruku, superam o limite recomendado pela Organização Mundial da Saúde em 58% das amostras sanguíneas (MOLINA, 2023). As operações do Ministério do Trabalho resgataram trabalhadores submetidos a dívidas coercitivas, sistema que lembra servidão e ainda prevalece em polos auríferos como a Floresta Nacional do Amaná (MOLINA, 2023).

A fragilidade da cadeia comercial amplia o problema. O ouro extraído em Permissões de Lavra Garimpeira deveria ser vendido a Distribuidoras de Títulos e Valores Mobiliários, mas apenas oito dessas empresas mantinham postos ativos em 2021. Três delas (Carol DTVM, Ourominas e FD'Gold) compraram juntas mais de quatro toneladas de ouro sem comprovação de origem entre 2019 e 2020 (MOLINA, 2023). A legislação atual presume a boa-fé do vendedor, o que transfere toda a responsabilidade da origem para quem entrega a mercadoria e abre espaço para lavagem.

A situação é agravada pela presença de facções criminosas, que controlam rotas de mercúrio, cobram taxas sobre a produção e oferecem proteção armada em frentes ativas, sobretudo em Roraima e no norte do Pará (INSTITUTO IGARAPÉ, 2021). Na fronteira venezuelana um grupo criminoso da Venezuela exerce papel semelhante na Terra Yanomami. Nesses circuitos, o ouro ilegal circula como moeda de troca por armas e drogas, graças ao seu alto valor agregado e à baixa fiscalização alfandegária (GLOBAL INITIATIVE, 2023).

Os dossiês *Terra Rasgada* e *Amazon Underworld* convergem ao apontar quatro obstáculos principais e respectivas ações recomendadas:

1. **Rastreabilidade do ouro.** A falta de nota fiscal eletrônica e a verificação documental superficial favorecem fraude. Propostas como selagem digital ou uso de blockchain ainda não saíram do papel (MOLINA, 2023).
2. **Fiscalização fragmentada.** Agência Nacional de Mineração, Banco Central, Receita Federal, Ibama e Funai têm competências sobrepostas, o que cria vazios de supervisão (MOLINA, 2023).
3. **Proteção a defensores ambientais.** Lideranças indígenas e servidores enfrentam ameaças e ataques armados, o que dificulta operações de repressão (GLOBAL INITIATIVE, 2023).
4. **Integração tecnológica.** O uso contínuo de séries Sentinel-2 ou Landsat no GEE ainda é incipiente nos órgãos de controle, mas pode gerar alertas em tempo quase real.

Entre as medidas propostas estão a declaração eletrônica de origem em toda a cadeia, a homologação célere de Terras Indígenas, operações interagências permanentes entre Polícia Federal, Ibama e Funai e o reforço do monitoramento satelital público (MOLINA, 2023; GLOBAL INITIATIVE, 2023).

O garimpo ilegal, portanto, combina degradação ambiental, danos socioeconômicos e vínculos com macrocriminalidade. Esse panorama justifica o emprego de técnicas de visão computacional, em especial Redes Neurais, para gerar alertas ágeis, auditáveis e de ampla cobertura que reforcem políticas de fiscalização e proteção da Amazônia.

## **2.2 Sensoriamento remoto na Amazônia**

O sensoriamento remoto coleta informação da superfície sem contato direto com o alvo. A Amazônia é monitorada dessa forma desde a década de 1970 e quase todos os programas ambientais dependem dele. Nesse contexto, quatro parâmetros definem a utilidade de um sensor: o primeiro é a resolução espacial, que determina o tamanho do píxel; o segundo é a resolução espectral, isto é, o conjunto de faixas de onda registradas; o terceiro é a resolução radiométrica, ligada ao número de níveis digitais disponíveis; e por fim, o quarto é a resolução temporal, que indica a frequência de revisita do satélite (NOVO, 2010; SHIMABUKURO; PONZONI, 2007). A série Landsat inaugurou, em 1972, um registro contínuo a 30 m de detalhe e ciclo de 16 dias, possibilitando reconstruir 5 décadas de mudanças de cobertura na Amazônia.

Atualmente, 3 famílias de sensores ópticos respondem pela maior parte dos estudos de degradação florestal. O Sentinel-2 MSI, da Agência Espacial Europeia, oferece píxeis de 10 m e revisita de cinco dias, além de bandas na borda vermelha que aumentam a sensibilidade à vegetação estressada (ESA, 2023). O Landsat-8/9 OLI, gerenciado por USGS e NASA, mantém a tradição da série com 30 m de resolução e agora integra o produto harmonizado *Harmonized Landsat–Sentinel* (HLS) junto ao Sentinel-2 (USGS, 2022). O Amazônia-1 WFI, primeiro satélite óptico inteiramente brasileiro, fornece uma faixa de 850 km e 64 m de resolução, útil para mosaicos regionais (INPE, 2021). Sensores de radar, como o Sentinel-1 em banda C, atravessam nuvens e garantem continuidade na estação chuvosa (ESA, 2022). Já o GEDI LiDAR, instalado na *International Space Station* (ISS), mostra altura de dossel e biomassa e disponibiliza seus produtos dentro do próprio GEE (NASA, 2021). Agora, produtos de média resolução (MODIS, VIIRS) completam a visão quando se requer uma série diária.

Entretanto, é importante ressaltar que a Amazônia desafia qualquer programa de observação, pois a nebulosidade média anual supera 70% e pode chegar a 90% na estação chuvosa (GLOBAL CLOUD BIAS, 2024). Então surgem 3 estratégias que mitigam o problema. Primeiro, os mosaicos temporais de um a três meses no GEE reduzem lacunas de nuvem. Segundo, máscaras como *Fmask 4.0* removem nuvens e sombras em Landsat e Sentinel-2 com acurácia superior a 96% (ZHU; WOODCOCK, 2019). Terceiro, a fusão óptico-radar, por exemplo, Sentinel-2 com Sentinel-1, mantém a detecção de clareiras recentes em ausência de cenas ópticas limpas (ARCANJO et al., 2023).

O GEE facilita esse pré-processamento, pois coleções como Landsat, Sentinel e CBERS já vêm ortorretificadas e corrigidas. Tutoriais públicos, como “*Forest cover and loss estimation*”, mostram como calcular estatísticas em escala de bacia, ampliar filtros espectrais e exportar *patches* prontos para redes neurais (GOOGLE EARTH ENGINE, 2025). A própria plataforma inclui versões abertas de *s2cloudless* e *Fmask*, além de módulos para índices padrão como NDVI, NDWI e NBR.

Para detectar garimpo em imagens de satélite interessam índices que contrastam com o solo exposto e com a água turva. Assim, combinações de índices como  $NDVI < 0,3$  e  $NDWI > 0,15$ , somadas a anomalias nas bandas SWIR, distinguem frentes de garimpo de clareiras agrícolas (TORRES et al., 2021). As bandas de borda-vermelha do Sentinel-2 reforçam a separação por salientar o solo laterítico típico das cavas.

Deste modo, a integração de sensores ópticos, radar e LiDAR, processada em nuvem, fornece um repositório massivo e gratuito, atualizado quase diariamente. Quando se reconhecem as limitações de nebulosidade, variação atmosférica e diferenças de resolução, e se aplicam máscaras avançadas e fusão óptico-radar, obtém-se mosaicos confiáveis até mesmo na região mais úmida do planeta. Esse arcabouço técnico sustenta o modelo de visão computacional desenvolvido nesta pesquisa, capaz de analisar séries multiespectrais extensas e detectar garimpo ilegal.

### **2.3 Características espectrais do garimpo ilegal**

Quando uma frente de garimpo se instala, a primeira consequência visível é a remoção completa da vegetação. O solo restante é rico em óxidos de ferro que refletem fortemente no infravermelho de ondas curtas, localizado entre 1,6 e 2,2  $\mu\text{m}$ , e refletem pouco no infravermelho próximo, centrado em 0,8  $\mu\text{m}$ . Esse contraste derruba os valores do NDVI,

índice que compara a resposta do NIR com a do vermelho para quantificar a presença de cobertura vegetal (LOBO, SOUZA-FILHO e NOVO, 2018).

Enquanto isso, a lavagem do cascalho forma plumas de sedimento que deixam a água turva. A turvação aumenta a refletância da banda verde e também do SWIR, elevando o NDWI, índice que realça corpos d'água quando assume valores positivos. Rios normalmente escuros passam a se destacar, criando um sinal claro de perturbação (TORRES et al., 2021).

Estudos comparativos indicam que a razão direta entre SWIR e NIR, combinada com a banda de borda vermelha do Sentinel-2 em 705 nm, diferencia garimpo ativo de clareiras agrícolas com mais de 85% de precisão (CAMALAN et al., 2022). Trabalhos mais recentes mostram que a fusão de índices de vegetação com imagens de super-resolução, obtidas por técnicas Redes Adversárias Generativas (GAN), aumenta ainda mais a separabilidade espectral e reduz falsos positivos em áreas de solo exposto vinculadas à agricultura (CUTRIM, 2021).

## 2.4 Pré-processamento de imagens no Google Earth Engine (GEE)

O Google Earth Engine, ou GEE, é uma infraestrutura em nuvem criada pela Google para análises geoespaciais em escala planetária. Desde o lançamento público em 2010 o serviço passou a hospedar um catálogo que já ultrapassa 70 petabytes de imagens de satélite, reunindo coleções Landsat, Sentinel, MODIS, CBERS, Amazônia-1 e outras bases auxiliares. Como o volume de dados permanece nos servidores, o pesquisador envia apenas um *script* com a descrição das operações, escrito em JavaScript ou Python, e o motor do GEE executa essas instruções em uma avaliação, distribuindo o trabalho em *clusters* próximos do repositório. Tarefas como gerar um mosaico trimestral livre de nuvem para toda a Amazônia ou calcular um índice espectral em milhões de cenas terminam em minutos, mesmo quando o usuário trabalha em um computador modesto (GORELICK et al., 2017).

Além de operações clássicas de *raster* e *vector*, como reamostragem, reduções espaciais, cálculos de índice, união de camadas, o GEE oferece algoritmos de aprendizado de máquina que rodam no próprio servidor, entre eles *Random Forest* (RF), *Classification and Regression Tree* (CART) e *Support Vector Machine* (SVM), descritos em sua documentação oficial e também por Gorelick et al. (2017). Quando a aplicação exige redes profundas, como *Convolutional Neural Networks* (CNNs) ou *Transformers*, a prática recomendada consiste em gerar no próprio GEE *patches* já rotulados e exportá-los em *TFRecord*, deixando o treinamento para ambientes que suportam *TensorFlow* ou *PyTorch*. Dessa forma o

pré-processamento de grande volume fica no ambiente escalável do GEE enquanto a modelagem aproveita bibliotecas especializadas.

Projetos brasileiros ilustram a utilidade dessa abordagem. O MapBiomass, por exemplo, está ativo desde 2015, produzindo suas séries anuais de cobertura e uso da terra inteiramente no GEE, combinando mosaicos Landsat, Sentinel-2 e CBERS com *Random Forest* regionais para cada bioma (MAPBIOMAS, 2025 c). Já, o Brazil Data Cube, iniciativa do INPE, constrói cubos espaço-temporais de imagens CBERS-4/4A e Amazônia-1 também dentro da plataforma, oferecendo produtos de 64 metros de resolução prontos para análise de mudança (ARCANJO et al., 2023).

Esses precedentes sustentam a escolha do GEE para esta pesquisa. A plataforma reúne em um único ponto as coleções Sentinel-2 de 10 metros e Landsat-8/9 de 30 metros que servirão de insumo ao modelo, disponibiliza filtros de nuvem prontos como *Fmask* e *s2cloudless*, algo essencial em uma região cuja nebulosidade média anual supera 70%, e oferece ferramentas de amostragem estratificada que aceleram a criação de conjuntos balanceados de *patches* rotulados. Também favorece a divulgação científica, pois os *scripts* desenvolvidos e hospedados no *Code Editor* do GEE ou na API Python presente no Google Colab podem ser compartilhados facilmente para garantir reproduzibilidade.

Em resumo, o GEE constitui o ambiente computacional usado nesse trabalho para coleta de dados, mascaramento atmosférico, geração de índices espectrais e exportação dos blocos que alimentarão a rede neural convolucional apresentada nos capítulos seguintes.

## **2.5 Visão computacional e aprendizado de máquina em sensoriamento remoto**

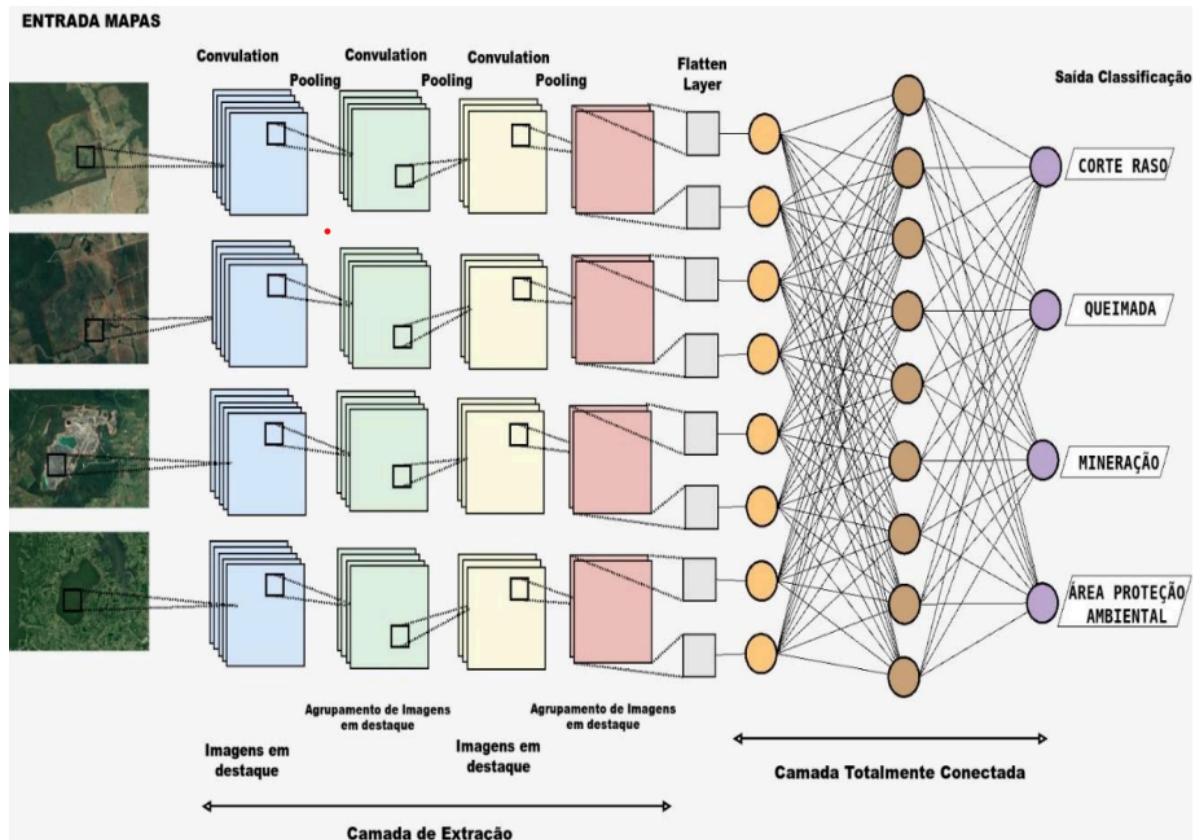
O aprendizado de máquina pode ser definido como o estudo de algoritmos que melhoram seu desempenho em uma tarefa à medida que acumulam experiência, sendo essa melhoria medida por uma métrica de desempenho adequada (GOODFELLOW, BENGIO, COURVILLE, 2016). No sensoriamento remoto, as tarefas mais comuns incluem a classificação da cobertura do solo, a segmentação de objetos e a detecção de mudanças. Assim, quatro paradigmas organizam essas abordagens, o supervisionado, o não supervisionado, o semi-supervisionado e o aprendizado por reforço.

Modelos “rasos”, como *Random Forest* ou Máquinas de Vetores de Suporte, dependem de atributos calculados manualmente, como bandas individuais, índices como NDVI ou NDWI e medidas de textura. Esses métodos exigem conhecimento prévio da assinatura espectral de cada classe e podem falhar quando a cena combina solo exposto, água

turma e sombra, mistura típica dos garimpos (BREIMAN, 2001; CORTES; VAPNIK, 1995). Redes neurais profundas, por outro lado, aprendem representações diretamente dos dados brutos. As camadas convolucionais resolvem dois desafios clássicos, elas reduzem a quantidade de parâmetros graças ao compartilhamento de filtros e capturam contexto espacial ao ampliar progressivamente o campo de visão (GOODFELLOW, BENGIO, COURVILLE, 2016).

A Figura 2 apresenta o fluxo típico de uma CNN. O cubo multiespectral entra na primeira camada convolucional, que identifica bordas simples e as camadas posteriores combinam esses traços e passam a reconhecer texturas. No final, um bloco totalmente conectado sintetiza as características extraídas e produz a probabilidade de cada classe (GOODFELLOW, BENGIO, COURVILLE, 2016). Com isso, testes em mineração aluvial na Amazônia relatam ganhos de até quinze pontos percentuais em *F1-score* quando CNNs são utilizadas para substituir classificadores baseados em atributos (CAMALAN et al., 2022).

Figura 2 – Arquitetura de uma CNN para Detecção de Impactos Ambientais Multiclasses.



Fonte: Rodrigues (2024, p. 33).

Além disso, detectar garimpo na Amazônia impõe três dificuldades adicionais:

1. **Desequilíbrio de classes:** áreas de garimpo ocupam poucos pixels, por isso técnicas como *oversampling*, *focal loss* ou métricas focadas em precisão e revocação ajudam a reduzir o viés (BUDA; MAKI; MAZUROWSKI, 2018).
2. **Ruído atmosférico e nuvens:** máscaras automáticas, como *Fmask 4.0*, podem elevar o *F1-score* até doze pontos percentuais quando aplicadas sistematicamente às coleções Landsat e Sentinel (ZHU; WOODCOCK, 2019).
3. **Heterogeneidade espectral:** solos lateríticos, sombras e água turva produzem assinaturas confusas para modelos lineares, mas redes profundas captam essas não linearidades com mais facilidade (LOBO; SOUZA-FILHO; NOVO, 2018).

Em bases desbalanceadas a acurácia global pouco informa, pois o modelo pode obter alta acurácia acertando as ocorrências da classe majoritária. De modo que, métricas como precisão, revocação e *F1-score* descrevem o equilíbrio entre falsos positivos e falsos negativos. Já a área sob a curva Precisão-Revocação (AUC-PR) resume esse equilíbrio ao longo de vários limiares e é recomendada quando a classe positiva é rara (SOKOLOVA; LAPALME, 2009).

O aprendizado profundo, portanto, oferece ferramentas que enfrentam o desequilíbrio, o ruído atmosférico e a variabilidade espectral característicos da Amazônia, desde que se combine métricas adequadas e filtros robustos. A próxima seção detalha a arquitetura das Redes Neurais Convolucionais, base tecnológica deste estudo.

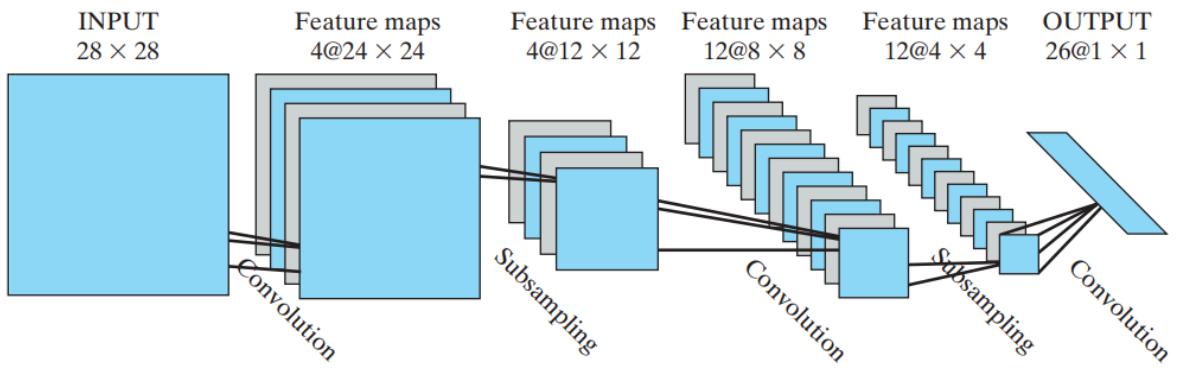
## 2.6 Redes Neurais Convolucionais (CNNs)

As Redes Neurais Convolucionais, mais conhecidas pela sigla CNN, unem três ideias que nasceram em momentos diferentes da pesquisa em visão computacional. A primeira, proposta em 1962 por Hubel e Wiesel, mostrou que neurônios no córtex visual de mamíferos respondem a padrões locais, por exemplo, bordas com determinada orientação (1962, p. 364 apud GOODFELLOW, BENGIO, COURVILLE, 2016). A segunda apareceu com o perceptron multicamada, que introduziu o treinamento por retropropagação. A terceira veio com o conceito de peso compartilhado, que reduz a quantidade de parâmetros porque o mesmo filtro percorre toda a imagem. Goodfellow, Bengio e Courville definem a CNN como uma rede em que pelo menos uma camada troca a multiplicação matricial tradicional por uma operação de convolução, isto é, correlações lineares aplicadas a janelas pequenas de uma

grade bidimensional ou tridimensional (GOODFELLOW, BENGIO, COURVILLE, 2016). Haykin descreve a mesma arquitetura como uma especialização do perceptron capaz de reconhecer formas mesmo quando elas mudam de posição, escala ou apresentam distorções, algo alcançado pela combinação de extração local de características, filtros compartilhados e etapas de *subsampling* (HAYKIN, 2009).

Durante o treinamento as CNN constroem uma hierarquia de representações, como mostrado na Figura 3. Filtros iniciais detectam bordas e cantos, logo depois surgem texturas e pequenos motivos, e finalmente as camadas mais profundas integram a informação para diferenciar, por exemplo, uma clareira agrícola de uma frente de garimpo com pluma de sedimento. Esse aprendizado de características dispensa a criação manual de índices, pois a própria rede descobre as combinações de bandas e padrões espaciais importantes para a tarefa (HAYKIN, 2009).

Figura 3 – Hierarquia de representações em uma CNN (entrada, *feature maps* e saída).



Fonte: Haykin (2009, p. 202)

Embora eficientes, as CNNs costumam ser vistas como caixas-pretas, pois suas decisões resultam de milhões de operações não lineares difíceis de rastrear individualmente. Para mitigar essa opacidade, a literatura de Inteligência Artificial Explicável desenvolveu ferramentas como o Grad-CAM, que projeta gradientes sobre mapas de ativação, e o LIME, que testa a sensibilidade do modelo a perturbações na entrada (SELVARAJU et al., 2017). O uso, mesmo que teórico, desses conceitos atende ao princípio de auditabilidade defendido por Haykin, segundo o qual sistemas de aprendizado que motivam decisões públicas, como as multas ambientais, que devem idealmente oferecer meios de inspeção crítica.

Em síntese, ao reunir as ideias de Goodfellow e Haykin, as CNNs são adotadas neste trabalho por seu viés estrutural favorável ao processamento de imagens, uma vez que

aprendem representações complexas por meio de convoluções e compartilhamento de pesos e dispensam a engenharia manual de atributos.

## 2.7 Trabalhos relacionados

A detecção automatizada de garimpo e outras atividades ilegais na Amazônia tem sido investigada em diferentes níveis de detalhe, combinando sensoriamento remoto, aprendizado de máquina e visão computacional. Os estudos abaixo ilustram a evolução das abordagens e apontam lacunas que esta pesquisa busca suprir.

O trabalho intitulado “Aprimoramento da Detecção de Áreas de Garimpo na Região do Tapajós através de Redes Adversárias de Super-Resolução”, de CUTRIM (2021), utilizou imagens de satélite Landsat 8 e de referência *RapidEye* e técnicas de sensoriamento remoto para identificar áreas de garimpo ilegal na região do Tapajós, no Pará. O estudo destacou a importância de métodos para melhorar a resolução das imagens de satélite por meio de Redes Adversárias Generativas (GANs, especificamente SRGAN e ESRGAN), que, combinadas com a Rede Neural Convolucional U-Net, aprimoraram a detecção de regiões degradadas pelo garimpo ilegal, como clareiras ou superfícies de solo exposto, em áreas de difícil acesso. Os resultados demonstraram ganhos de até 15% nas métricas de detecção, alcançando 86% de *F1-Score* no melhor cenário (ESRGAN/U-Net) (CUTRIM, 2021).

Outro exemplo é o trabalho de conclusão de curso de LIMA (2022), intitulado “Mapeamento das áreas de garimpo em terras indígenas Munduruku utilizando modelo baseado em conhecimento e integração multisensores”, que desenvolveu um modelo de classificação para identificação e mapeamento de áreas de garimpo em terras indígenas na Amazônia, como foco especial na Terra Indígena Munduruku, uma das mais afetadas pela mineração ilegal. O estudo proposto por ela traz uma abordagem baseada em conhecimentos utilizando imagens dos satélites Landsat 5, Landsat 8 e CBERS-4A para uma análise temporal dos anos de 2010, 2016, 2018 e 2021, caracterizando um estudo multisensor. Na modelagem foram utilizados algoritmos de classificação supervisionado, como *Random Forest* (RF), *Support Vector Machine* (SVM) e *Geographic Object-Based Image Analysis* (GEOBIA), além de índices espectrais como Índice de Vegetação de Diferença Normalizada (NDVI) e Índice de Água Diferença Normalizada (NDWI). O modelo final, baseado na integração desses conhecimentos, foi validado com um excelente Índice Kappa de 0,94 e Exatidão Global de 96,75%. Os resultados obtidos com a aplicação destes modelos mostraram um crescimento

acelerado das áreas de garimpo, em que de 2016 até 2021, a área minerada aumentou em mais de 936% (LIMA, 2022).

Já no campo da inteligência artificial aplicada ao monitoramento ambiental na Amazônia, destaca-se a tese de doutorado de RODRIGUES (2024), intitulada “Inteligência Artificial para Analisar o Desmatamento na Região Amazônica Brasileira”. O trabalho em questão propõem uma análise utilizando geoprocessamento, sensoriamento remoto e inteligência artificial para analisar o desmatamento na região Amazônica brasileira entre os anos de 2001 e 2022, onde o estudo utilizou imagens de satélite e dados do PRODES/INPE para classificar áreas segundo as classes de corte raso, queimadas, mineração e áreas de proteção ambiental, com foco nas regiões Altamira e São Félix do Xingu, no Pará. Foram aplicados e comparado os algoritmos *K-Nearest Neighbors* (KNN), *Random Forest* (RF) e Redes Neurais Convolucionais (RNC), sendo que este último modelo apresentou os melhores resultados em métricas de acurácia, precisão e F1-score. Embora a classe Mineração tenha apresentado a precisão mais baixa no RNC (69,04%), o modelo ainda assim superou o desempenho dos outros algoritmos para essa classe, destacando a capacidade da CNN em lidar com classes de difícil detecção (RODRIGUES, 2024). Tendo como principal contribuição a integração de dados espaciais com técnicas de aprendizado de máquina para mapeamento multiclasse de alterações ambientais, demonstrando o potencial da inteligência artificial para aprimorar a detecção de padrões complexos em imagens multitemporais da Amazônia. Embora o foco principal tenha sido o desmatamento como um todo, os métodos empregados e os resultados obtidos fornecem contribuições valiosas para diferentes abordagens mais específicas, como a proposta deste trabalho, voltada à detecção de garimpo ilegal.

Fora do Brasil, Gallwey et al. (2020) desenvolveram a primeira Rede Neural Convolucionial U-Net multiespectral para a detecção automática de Mineração Artesanal e em Pequena Escala (ASM) na região Sul de Gana, utilizando imagens do satélite Sentinel-2. O modelo utilizou 10 bandas espectrais (incluindo as bandas SWIR) para aprender as características espaciais e espectrais do garimpo. O método demonstrou desempenho superior aos classificadores tradicionais, alcançando um Mine Class IoU (*Intersection Over Union*) de 0,86 em dados vistos e 0,82 em dados não vistos, destacando a forte capacidade de generalização da CNN e confirmado que esta metodologia é altamente adequada para o mapeamento e monitoramento em larga escala do garimpo (GALLWEY et al., 2020).

No contexto da Amazônia Internacional, Camalan et al. (2022) abordaram o desafio de detectar mudanças em lagoas de Garimpo Aluvial em Pequena Escala (ASGM) na região de

Madre de Dios, no Peru, utilizando séries temporais de imagens Sentinel-2. Os autores propuseram o modelo E-ReCNN (Extended Recurrent Convolutional Neural Network), que combina a capacidade espacial das CNNs com a análise temporal das LSTMs. O estudo demonstrou que o pré-processamento das imagens Sentinel-2 via *Histogram Matching* foi essencial, elevando o F1-Score de 0,71 para 0,88. O modelo mais eficaz (E-ReCNN, 6 canais) alcançou F1-Score de 0,88 e Jaccard (IoU) de 0,88 para a detecção de mudanças na região focal. Adicionalmente, o E-ReCNN demonstrou forte capacidade de generalização em regiões *out-of-sample* (mantendo Kappa de 0,90), confirmando a adequação de modelos profundos e multitemporais para o monitoramento preciso e escalável da dinâmica do garimpo aluvial na Amazônia (CAMALAN et al., 2022).

Com isso, é possível levantar e apontar nesses trabalhos relacionados às principais métricas, indicadores e resultados obtidos com cada um dos objetivos apresentados, para avaliar de forma comparativa o desempenho dos modelos abordados em cada um dos cenários, conforme a Tabela 1.

Tabela 1 – Comparaçāo entre os modelos observados na revisão bibliográfica aos trabalhos relacionados.

Autor / Ano	Área / Região	Objetivo Principal	Modelo(s) utilizado(s)	Dados e recorte espacial / temporal	Principais Resultados / Métricas	Contribuições Relevantes
Rodrigues (2024)	Municípios de Altamira e São Félix do Xingu (PA), na Amazônia Brasileira.	Análise de desmatamento (corte raso, queimadas, mineração) via classificação de imagens de satélite (CBERS-4, 2001-2022).	K-Vizinhos Mais Próximos (KNN), Floresta Aleatória (RF) e Rede Neural Convolutional (RNC).	Imagens do satélite CBERS-4 (Sensor WFI, 12 bandas espectrais, resolução 64m) e bases de dados do PRODES, de 2001 a 2022.	RNC (Acurácia: 97,4%, Kappa: 80,4%) superior; Mineração (Precisão RNC: 69,04%, F-Score RNC: 81,7%, Precisão KNN: 54,76% e Precisão RF: 52,38%).	Demonstra superioridade da RNC na classificação de desmatamento e mineração, tendo maior complexidade em imagens espectrais.
Cutrim (2021)	Região de Integração do Tapajós (PA), Amazônia Brasileira.	Desenvolver metodologia com GANs (SR) para aprimorar imagens Landsat 8 e melhorar detecção de garimpo com U-Net (2014).	Redes Adversárias de Super-Resolução (SRGAN, ESRGAN) para melhoramento da imagem, seguidas de Rede Neural Convolutional U-Net para segmentação e detecção de garimpo.	Imagens de satélite Landsat 8 (baixa resolução, 30m) e RapidEye (alta resolução, 5m) utilizadas como referência, datadas em 2014.	Ganhos de até 15% na detecção de garimpo. Melhor modelo (ESRGAN BS2 + U-Net): ACC: 86%; SENS: 80%; PREC: 94%; F1-Score: 86%. (F1 Baseline original: 76%).	Super-Resolução (ESRGAN) aprimora significativamente a detecção de garimpo com U-Net, especialmente para garimpos menores.

Lima (2022)	Terra Indígena Munduruku (PA), região do Tapajós.	Mapear e analisar a expansão de garimpo (2010-2021) em TI Munduruku usando Modelo Baseado em Conhecimento e multissensores.	Modelo Baseado em Conhecimento (Modelo 5), integrando: Random Forest (RF), Support Vector Machine (SVM) e GEOBIA; e dados auxiliares (MapBiomas, PRODES, NDVI).	Imagens Landsat 5, Landsat 8 e CBERS 04A (multissensores), no período de 2010, 2016, 2018 e 2021 (área de estudo e área piloto).	Modelo 5 (mais eficaz com RF e SVM usados para classificação da classe Garimpo com dados do MapBiomas): Kappa: 0,94; Exatidão Global: 96,75% (2021).	Método de classificação baseado em conhecimento eficaz para detecção multiclasse (incluindo garimpo), superando classificação pixel a pixel. Fornecendo dados robustos sobre a expansão acelerada do garimpo (936,6% entre 2016 e 2021).
Gallwey et al. (2020)	Sul de Gana, Craton Oeste Africano (6 milhões de hectares).	Desenvolver e validar CNN multiespectral (U-Net) para detecção automática de Garimpo Artesanal (ASM) e desmatamento com Sentinel-2 (2015-2019).	Rede Neural Convolucional U-Net (multiespectral, 10 canais), comparada a classificadores tradicionais (Random Forest, Multi-Layer Perceptron, SAM).	Imagens multiespectrais Sentinel-2 (10 bandas, 10m/20m de resolução) sobre o sul de Gana, cobrindo o período de 2015 a 2019 (4 anos).	Média IoU de 0,87 (vistos) e 0,83 (não vistos); Mine Class IoU de 0,86 (vistos) e 0,82 (não vistos); erros de omissão/comissão abaixo de 8%.	Primeira CNN multiespectral para detecção de ASM em Sentinel-2. Com forte capacidade de generalização e escalabilidade para monitoramento nacional.
Camalan et al. (2022)	Madre de Dios (MDD), Peru (Hotspot de Garimpo Aluvial na Amazônia). Testes out-of-sample em Venezuela, Indonésia e Mianmar.	Detectar e categorizar mudanças em lagoas de Garimpo Aluvial (ASGM) comparando Deep Learning (E-ReCNN) e Semi-Supervisão dos (SVM-STV) com Sentinel-2 (2019, 2021).	E-ReCNN (Extended Recurrent Convolutional Neural Network - Combinação de CNN e LSTM) para detecção de mudanças. Comparado com SVM-STV (Semi-Supervisionado).	Imagens Sentinel-2 multiespectrais, em pares bi-temporais (2019 e 2021). O melhor desempenho foi obtido com o set de 6 canais (RGB, NIR, SWIR1 e SWIR2) após Histogram Matching.	E-ReCNN (6 canais + Histogram Matching): Kappa: 0,92; Jaccard: 0,88; F1-Score: 0,88. Generalização out-of-sample com: Kappa: 0,90; F1-Score: 0,77.	Modelo Deep Learning (E-ReCNN) preciso e escalável para detectar mudanças finas em lagoas de garimpo. Evidenciando que o pré-processamento (Histogram Matching) é essencial para ganhos significativos no F1-Score (de 0,71 para 0,88).

Fonte: Própria

Deste modo, esses trabalhos comprovam o avanço das CNNs no monitoramento ambiental em conjunto com imagens de satélite, porém revelam limitações recorrentes. Como o uso frequente de conjuntos de dados restritos ou proprietários que dificultam a reproduzibilidade científica e a dependência de pré-processamentos externos sem um fluxo integrado no GEE, o que reduz a escalabilidade operacional da solução.

### **3. METODOLOGIA**

A metodologia busca mostrar de forma clara como cada um dos blocos (fundamentação teórica, coleta, pré-processamento, modelagem, avaliação e divulgação), se conectam em uma estrutura de seis macro-etapas para formar o percurso metodológico completo deste projeto.

O primeiro passo consistiu na revisão da bibliografia, voltada a compreender os principais conceitos de aprendizado profundo, visão computacional aplicada ao sensoriamento remoto e impactos ambientais do garimpo ilegal na Amazônia. Nessa etapa também foram identificados trabalhos que já utilizam inteligência artificial para apoiar o monitoramento de desmatamento, mineração e outros impactos ambientais na floresta, servindo de base conceitual e comparativa para a presente pesquisa (RODRIGUES, 2024).

A segunda etapa envolveu a coleta de dados e a construção do dataset. Inicialmente foi definida uma região da Amazônia com proporção adequada de áreas com e sem garimpo, dando preferência a zonas de mineração ilegal sobre territórios protegidos legalmente no Brasil, como unidades de conservação e terras indígenas. Essa escolha foi apoiada em produtos cartográficos públicos, em especial as classes de mineração disponibilizadas pelo MapBiomass (MAPBIOMAS, 2025). Em seguida foram reunidas imagens de satélite de acesso aberto, capazes de representar bem o contraste entre floresta preservada, corpos d'água e áreas degradadas, além de bases vetoriais com polígonos de mineração mapeados na região, como os shapefiles do projeto RAISG, que fornecem a localização aproximada de frentes de garimpo na Amazônia (MAPBIOMAS, 2025; RAISG, 2025).

Na terceira etapa foi realizado o pré-processamento dos dados que consistiu em passar as imagens por máscaras de nuvens/sombras e também por composições temporais em mosaicos, com o objetivo de reduzir a interferência atmosférica e a variabilidade sazonal antes do recorte em *chips* (SENTINEL HUB, 2024). Em paralelo, desenvolveu-se uma análise exploratória dos dados (EDA) para investigar quais indicadores derivados das bandas espectrais e dos metadados ajudavam a discriminar imagens com garimpo daquelas sem garimpo. Nessa fase foram calculadas medidas como índice de excesso de verde (ExG), brilho médio, variância de desfoque e energia de borda, que serviram tanto para diagnóstico da qualidade do dataset quanto para modelos tabulares de aprendizado de máquina.

A quarta etapa concentrou-se na modelagem. Inicialmente foram treinados modelos clássicos de aprendizado de máquina, como Regressão Logística e *Random Forest* (RF), empregando apenas os atributos tabulares extraídos dos *chips*. Esses modelos forneceram um

ponto de partida para avaliar a separabilidade entre classes e estabelecer uma linha de base de desempenho, como um modelo de referência (*baseline*) (BREIMAN, 2001). A partir dessa referência, o trabalho avançou para modelos de aprendizado profundo, em especial redes neurais convolucionais, explorando arquiteturas personalizadas próprias e arquiteturas utilizando transferência de aprendizado (*transfer learning*) com reaproveitamento de pesos pré-treinados em outras bases de imagens. A ideia central foi permitir que as CNNs aprendessem padrões espaciais e espectrais mais finos (GOODFELLOW; BENGIO; COURVILLE, 2016; HAYKIN, 2009), associados à presença de clareiras, estradas de acesso e plumas de sedimento, aprimorando a distinção entre imagens com e sem garimpo.

A quinta etapa foi dedicada à avaliação quantitativa, que buscou medir a qualidade e a robustez dos modelos treinados. Para isso, o conjunto de dados foi dividido em subconjuntos de treino, validação e teste que permanecem isolados ao longo de todos os experimentos. A segregação do conjunto de validação mostrou-se essencial para o monitoramento da convergência das redes neurais e para a aplicação de técnicas de parada antecipada (*early stopping*), prevenindo o sobreajuste (*overfitting*) antes da avaliação final no conjunto de teste. Nesse contexto, a comparação entre modelos foi feita a partir de métricas clássicas em problemas de classificação binária como (SOKOLOVA; LAPALME, 2009):

1. **Precisão**, que mostra a proporção de alertas de garimpo que correspondem de fato a áreas de garimpo

$$\text{Precisão} = \frac{TP}{TP + FP} \quad (1)$$

em que  $TP$  representa o número de verdadeiros positivos e  $FP$  o número de falsos positivos. Valores elevados de precisão reduzem o risco de deslocamentos desnecessários de fiscalização.

2. **Revocação**, que indica a fração de áreas de garimpo corretamente identificadas pelo modelo

$$\text{Revocação} = \frac{TP}{TP + FN} \quad (2)$$

em que  $FN$  é o número de falsos negativos. Essa métrica expressa a capacidade de cobertura ambiental do modelo.

3. **F1-Score**, que combina precisão e revocação por meio da média harmônica, equilibrando simultaneamente omissões e comissões

$$F_1 = 2 \cdot \frac{\text{Precisão} \times \text{Revocação}}{\text{Precisão} + \text{Revocação}} \quad (3)$$

4. **AUC-PR** (área sob a curva de precisão–revocação), que sintetiza o desempenho do modelo ao longo de diferentes limiares de decisão. Essa métrica é especialmente indicada quando a classe positiva é rara, pois não é influenciada pela grande quantidade de verdadeiros negativos, ao contrário do que pode ocorrer com a AUC-ROC.

Assim, todos os experimentos são registrados com versão de pesos, métricas, hiperparâmetros e curvas de desempenho, de modo a permitir a reproduzibilidade e a comparação sistemática entre diferentes configurações de modelo e estratégias de pré-processamento.

Por fim, a sexta etapa contempla a divulgação externa e a publicação dos resultados. Deste modo, os códigos desenvolvidos, os pesos das redes, o dataset preparado e os notebooks utilizados desde a coleta de dados até a avaliação dos modelos serão disponibilizados em repositório público, permitindo que outros pesquisadores possam reproduzir, auditar ou estender o trabalho. Essa abertura reforça o compromisso com a transparência, reproduzibilidade e utilidade prática desta pesquisa para a comunidade interessada no monitoramento ambiental da Amazônia.

## 4. DESENVOLVIMENTO, RESULTADOS E DISCUSSÃO

Este capítulo apresenta as etapas realizadas para alcançar os objetivos propostos no presente trabalho, conectando o que foi obtido na prática com a metodologia descrita anteriormente. Com isso, busca-se mostrar que a abordagem proposta foi adequada, discutindo os dados gerados à luz da fundamentação teórica e dos desafios reais de monitorar o garimpo na Amazônia.

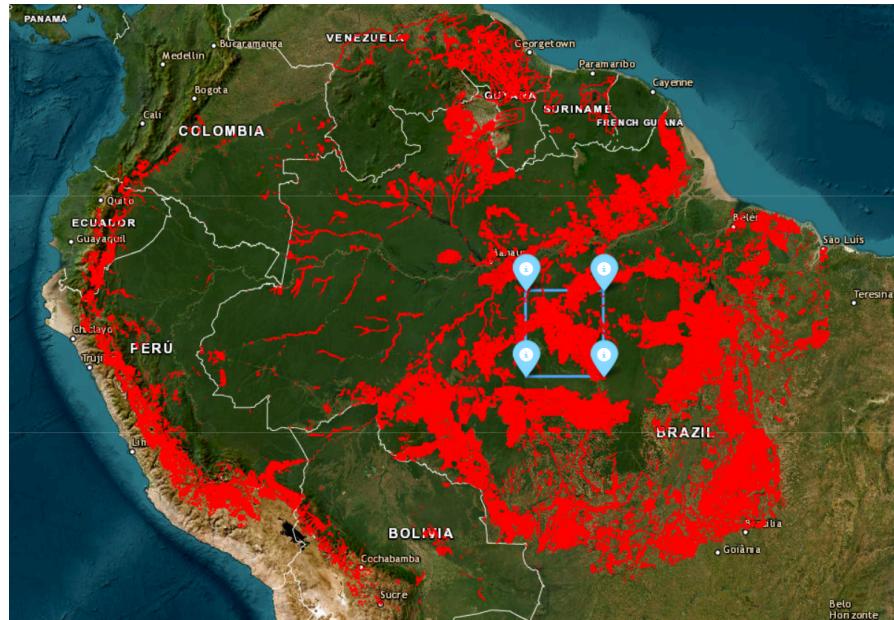
### 4.1 Coleta de dados

A coleta de dados foi realizada inteiramente no Google Earth Engine (GEE). Essa escolha permitiu processar o grande volume de imagens de satélite diretamente na nuvem, sem precisar fazer download para uma máquina local, seguindo a recomendação de Gorelick et al. (2017) para análises em larga escala.

A área de estudo foi definida cruzando a disponibilidade de boas imagens com locais onde o garimpo já é confirmado. A referência usada foi a camada "Mineração" da Coleção 9 do MapBiomas (MAPBIOMAS, 2025). A escolha do recorte geográfico buscou incluir uma grande variedade de cenários, desde áreas com muito garimpo ativo e sedimentos até regiões de floresta densa e rios limpos. Essa diversidade é essencial para treinar a rede neural, pois ajuda o modelo a aprender padrões gerais e evita que ele apenas decore características específicas de um único local, o chamado *overfitting* (GOODFELLOW; BENGIO; COURVILLE, 2016).

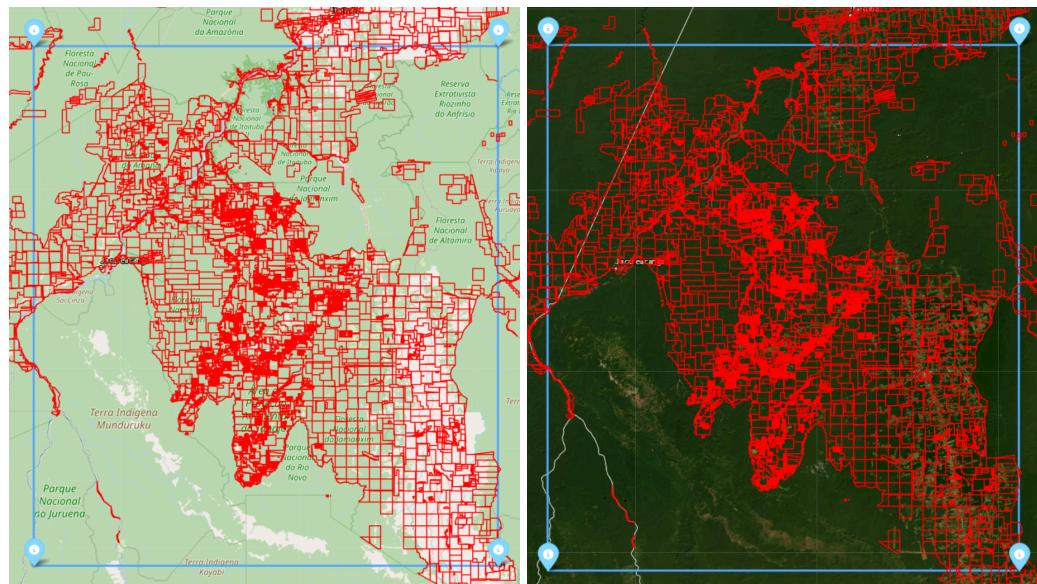
A Figura 4 mostra a região escolhida, com os polígonos de mineração da RAISG (2025) sobrepostos ao mosaico de imagens, enquanto a Figura 5 mostra essa mesma área de forma aproximada, permitindo visualizar os detalhes com maior clareza. Na análise visual, já foi possível confirmar os padrões citados por Lobo, Souza-Filho e Novo (2018), como a alta reflexão no infravermelho de ondas curtas (SWIR) onde há solo exposto e a mudança na cor dos rios devido à turbidez da água.

Figura 4 – Região selecionada da área de estudo com sobreposição do *shapefile* de mineração.



Fonte: Própria

Figura 5 – Região selecionada da área de estudo com sobreposição do *shapefile* de mineração ampliada.



Fonte: Própria

Durante o processamento, o maior desafio foi a quantidade de nuvens, algo comum na Amazônia. Para resolver isso, a coleção Sentinel-2 (Nível 2A) foi integrada com o algoritmo de aprendizado de máquina *s2cloudless* (SENTINEL HUB, 2024). Pois, diferente de usar

máscaras simples, esse método usa probabilidades para detectar melhor nuvens finas, gerando máscaras mais precisas.

Depois de aplicar as máscaras, foi criado um mosaico usando a mediana dos *pixels* válidos ao longo do tempo. Essa técnica ajuda a remover sombras e ruídos que os filtros iniciais deixaram passar, entregando uma imagem limpa (ZHU; WOODCOCK, 2019). As bandas B2, B3, B4, B8, B11 e B12 foram padronizadas para reflectância de superfície, garantindo que os valores numéricos estejam corretos para o cálculo dos índices e para a entrada na rede neural.

Para complementar e validar os dados, também foram processadas imagens dos satélites Landsat-8 e Landsat-9 (USGS, 2022). Mesmo com uma resolução de 30 metros, menor que os 10 metros do Sentinel-2 (ESA, 2023), a compatibilidade entre os sensores permitiu confirmar se as cicatrizes de garimpo existiam mesmo nas datas próximas, garantindo que o que se via na imagem não era erro de processamento.

Por fim, o GEE exporta os mosaicos para o Google Drive e gera uma grade regular de células com 2,56 km de lado. Essa grade serve como referência para o recorte dos *chips* que serão rotulados e encaminhados às etapas seguintes do *pipeline*. Desse modo, esse arranjo mantém o processo reproduzível e facilita repetir a coleta para outras janelas de tempo ou outras áreas quando necessário (GORELICK et al., 2017).

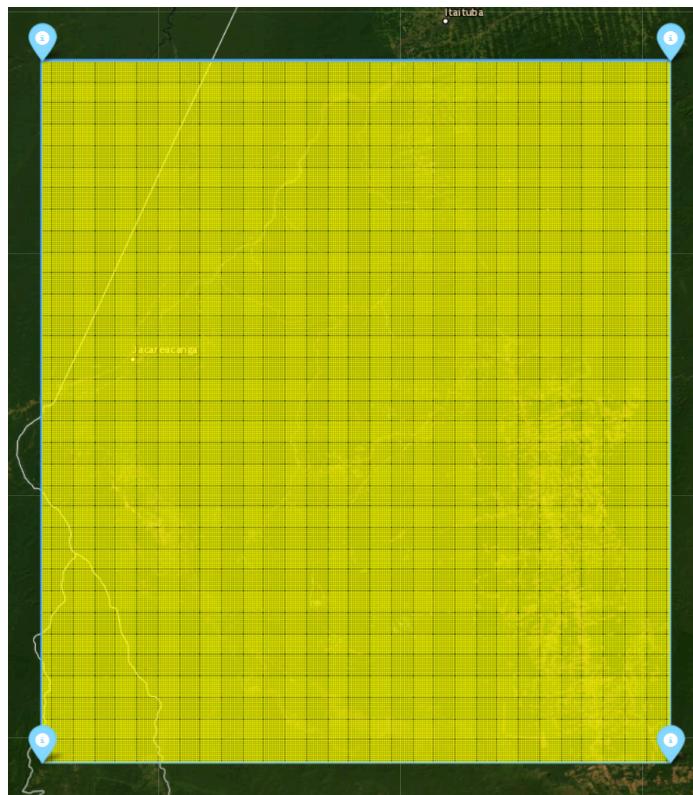
## 4.2 Construção do *Dataset*

A construção do dataset foi realizada em Python, processando os mosaicos exportados do Google Earth Engine em conjunto com os dados vetoriais. O objetivo desta etapa foi transformar as grandes imagens de satélite em pequenos recortes (conhecidos como *chips* ou *patches*) rotulados, formato padrão para o treinamento de Redes Neurais Convolucionais.

Inicialmente, os arquivos vetoriais de garimpo da RAISG foram carregados utilizando a biblioteca *geopandas* e re-projetados para o mesmo sistema de coordenadas dos mosaicos. Essa harmonização é obrigatória para garantir que, ao sobrepor o mapa de garimpo na imagem de satélite, os cálculos de área e interseção sejam exatos.

Em seguida, definiu-se uma grade regular de cortes diretamente sobre a imagem. Cada janela possui dimensões de 128x128 *pixels*. Considerando a resolução espacial de 10 metros do Sentinel-2, cada chip cobre uma área aproximada de 1,28 km<sup>2</sup>, o que preserva contexto espacial suficiente para que a rede visual distinga clareiras de mineração, margens de rio e plumas de sedimento. A Figura 6 ilustra melhor como essa grade cobre a região de estudo.

Figura 6 – Região selecionada da área de estudo com sobreposição dos recortes de *chips*.



Fonte: Própria

Para a rotulagem automática, desenvolveu-se um *script* que percorre essa grade utilizando a biblioteca *rasterio*. Para cada janela, o algoritmo calcula a interseção geográfica com os polígonos da RAISG. A regra de rotulagem adotada foi:

- **Classe "com\_garimpo" (Positiva):** Se mais de 5% da área do chip coincidir com um polígono de garimpo.
- **Classe "sem\_garimpo" (Negativa):** Caso contrário.

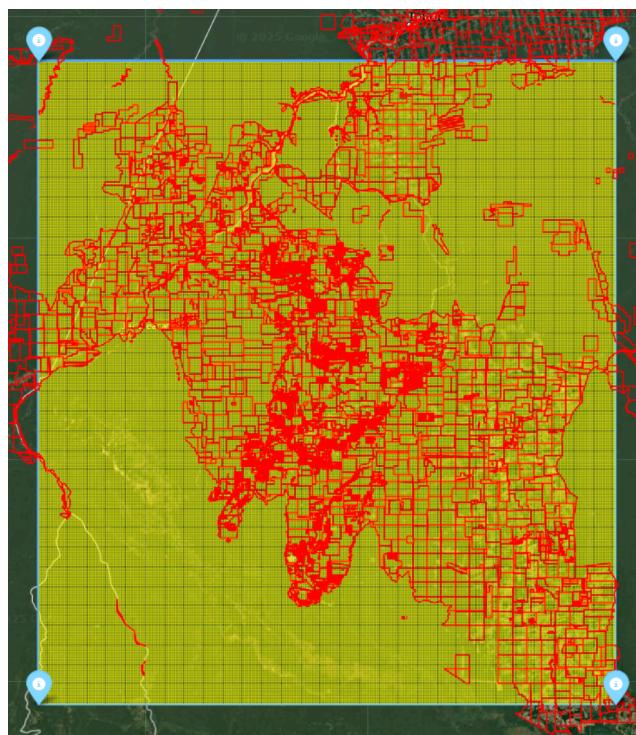
Esse limiar de 5% foi escolhido para evitar que recortes tocados apenas por uma borda pequena de polígono fossem considerados positivos (o que introduziria ruído), mas mantendo a sensibilidade para capturar frentes de garimpo que ainda estão no início e não ocupam todo o bloco.

As imagens foram salvas em formato PNG, utilizando uma composição RGB das bandas B4 (Vermelho), B3 (Verde) e B2 (Azul). Paralelamente à geração das imagens, o código produziu um arquivo "manifesto" em formato CSV. Esse documento registra os

metadados de cada amostra: caminho do arquivo, rótulo, coordenadas geográficas do centróide e a porcentagem exata de sobreposição com o garimpo. Assim, o manifesto serve como um índice para o conjunto de dados, facilitando auditorias futuras e permitindo rastrear qualquer amostra de volta à sua posição original no mapa.

A Figura 7 mostra o resultado final dessa sobreposição, onde é possível ver como a grade se alinha com as áreas de mineração mapeadas.

Figura 7 – Região selecionada da área de estudo com sobreposição do *shapefile* de mineração e recorte dos *chips*.



Fonte: Própria

A divisão final dos dados em conjuntos de treinamento e teste foi feita utilizando a biblioteca *scikit-learn*. Deste modo, aplicou-se uma separação estratificada (função *train\_test\_split* com parâmetro *stratify*), garantindo que a proporção entre classes se mantivesse idêntica nos dois grupos. A divisão padrão foi de 80% das imagens para treino e 20% para teste.

A Tabela 2 detalha a distribuição quantitativa final. Nota-se que, devido à seleção cuidadosa da área de estudo no passo anterior, o dataset resultante ficou naturalmente balanceado, com quantidades muito próximas de imagens com e sem garimpo, dispensando técnicas artificiais de balanceamento nesta fase.

Tabela 2 – Quantidade de imagens do conjunto de treino e teste considerando as classes com garimpo e sem garimpo.

<b>Conjunto</b>	<b>Com Garimpo</b>	<b>Sem Garimpo</b>	<b>Total</b>
<b>Treino</b>	44.432	44.834	89.266
<b>Teste</b>	11.109	11.209	22.318
<b>Total</b>	55.541	56.043	<b>111.584</b>

Fonte: Própria

Com isso, o resultado desse fluxo foi um conjunto de dados estruturado, com mais de 111 mil amostras rotuladas e rastreáveis, totalizando aproximadamente 2.6 GB, pronto para alimentar os modelos de aprendizado profundo descritos nas próximas sessões. Além disso, com a metodologia em código é possível que todo o processo possa ser reproduzido para novas áreas ou anos diferentes, bastando apenas apontar para os novos arquivos de entrada.

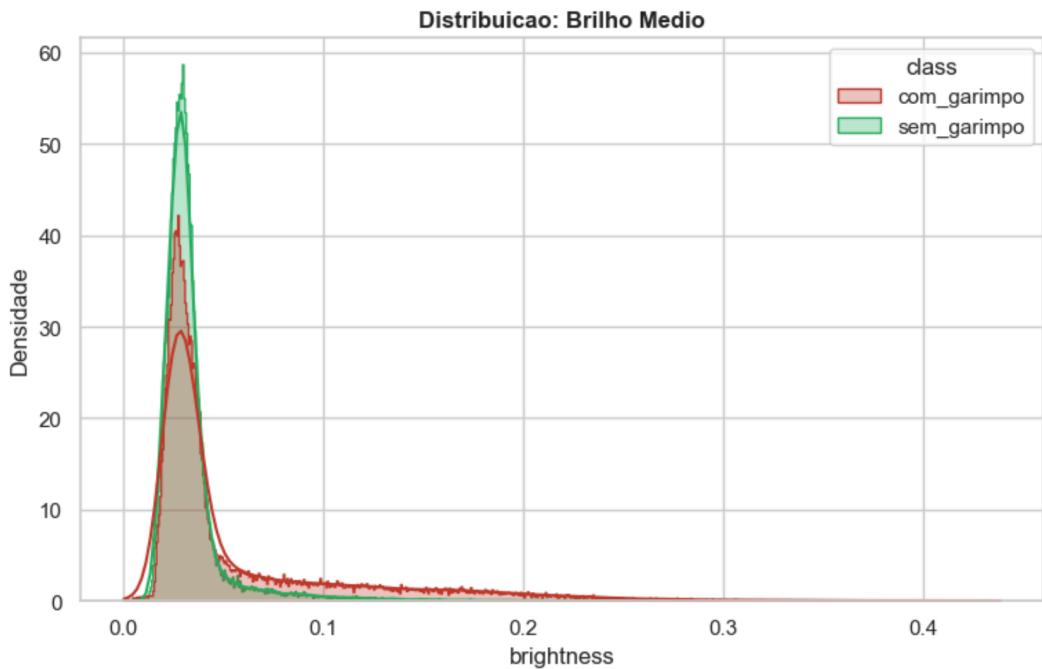
#### 4.3 Análise Exploratória de Dados (EDA)

Antes de submeter o conjunto de dados gerado ao treinamento das redes neurais profundas, conduziu-se uma Análise Exploratória de Dados (EDA). Esta etapa tinha 3 objetivos, o primeiro foi de validar a integridade dos metadados gerados, o segundo foi de avaliar a separabilidade das classes utilizando descritores de baixo custo computacional e o terceiro foi de estabelecer uma linha de base (*baseline*) de desempenho.

Para processar o volume massivo de dados (com mais de 111 mil imagens), foi implementada uma rotina em Python que extraiu estatísticas descritivas de cada *chip*, de forma paralela em CPU para acelerar o processo. Assim, foram analisados atributos espectrais, como o brilho médio e o índice de vegetação ExG (*Excess of Green*), e atributos estruturais, como a variância do Laplaciano (indicador de textura e nitidez) e a energia de borda (*Sobel*).

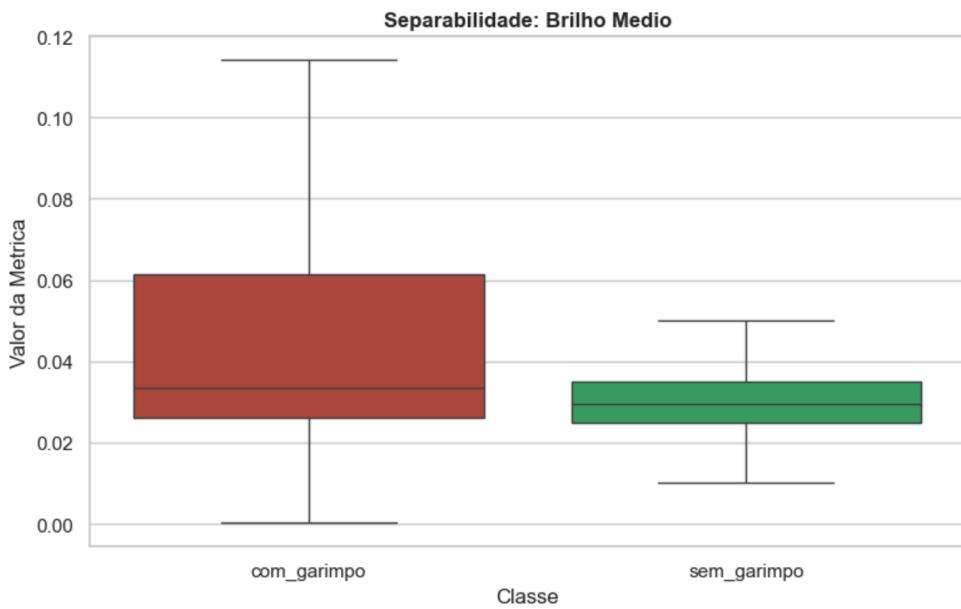
A primeira análise focou nas características de cor e luminosidade, derivadas diretamente das matrizes de intensidade dos canais RGB que compõem os arquivos de imagem PNG. Conforme observado na Figura 8 e nos *boxplots* da Figura 9, as áreas de garimpo tendem a apresentar um brilho médio superior às áreas de "não garimpo". Isso corrobora a premissa teórica de que o solo exposto e as águas turvas possuem maior reflectância global do que a floresta densa ou corpos d'água preservados.

Figura 8 – Gráfico de Distribuição do Brilho Médio.



Fonte: Própria

Figura 9 – Gráfico de Separabilidade do Brilho Médio.

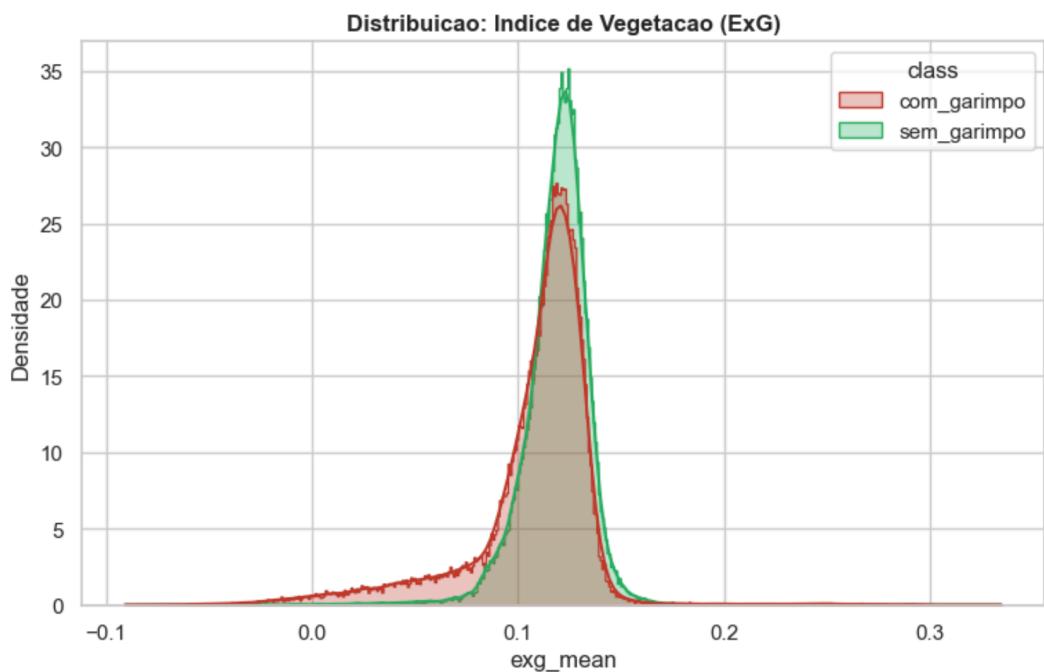


Fonte: Própria

Em contrapartida, a análise do índice de vegetação ExG, apresentada na Figura 10, revelou uma sobreposição considerável entre as classes. Embora a média do ExG seja

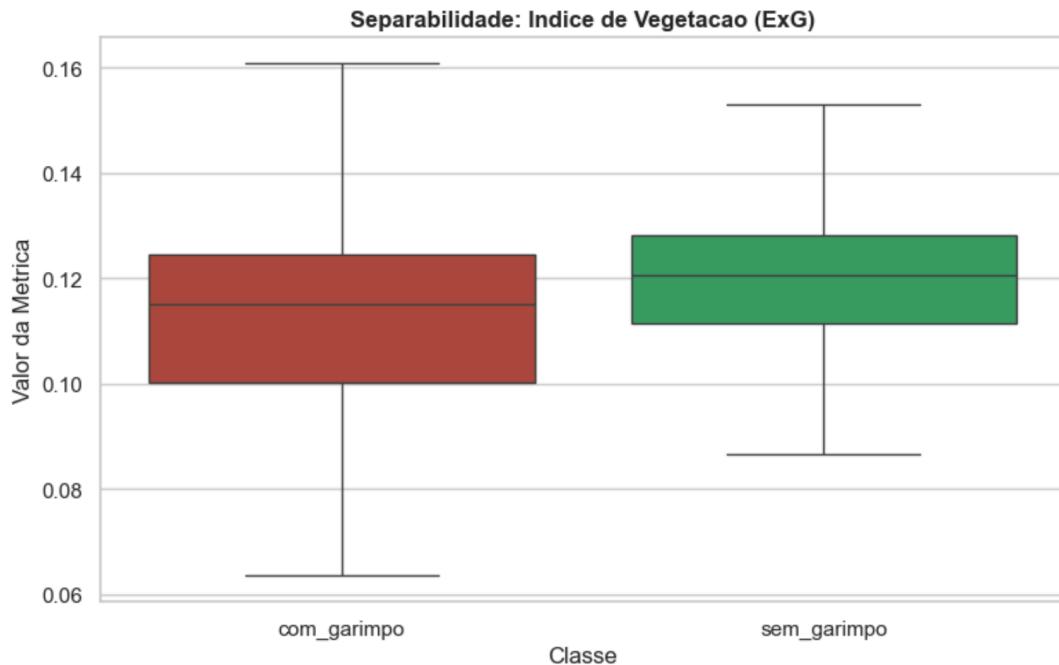
ligeiramente menor nas áreas de garimpo (indicando perda de cobertura vegetal), a variância é alta, como demonstrado na Figura 11. Isso demonstra que utilizar apenas a "ausência de verde" é insuficiente para caracterizar o problema, pois nuvens, rios e estradas também geram valores baixos de ExG, podendo induzir o modelo ao erro se analisados isoladamente.

Figura 10 – Gráfico de Distribuição do Índice de Vegetação (ExG).



Fonte: Própria

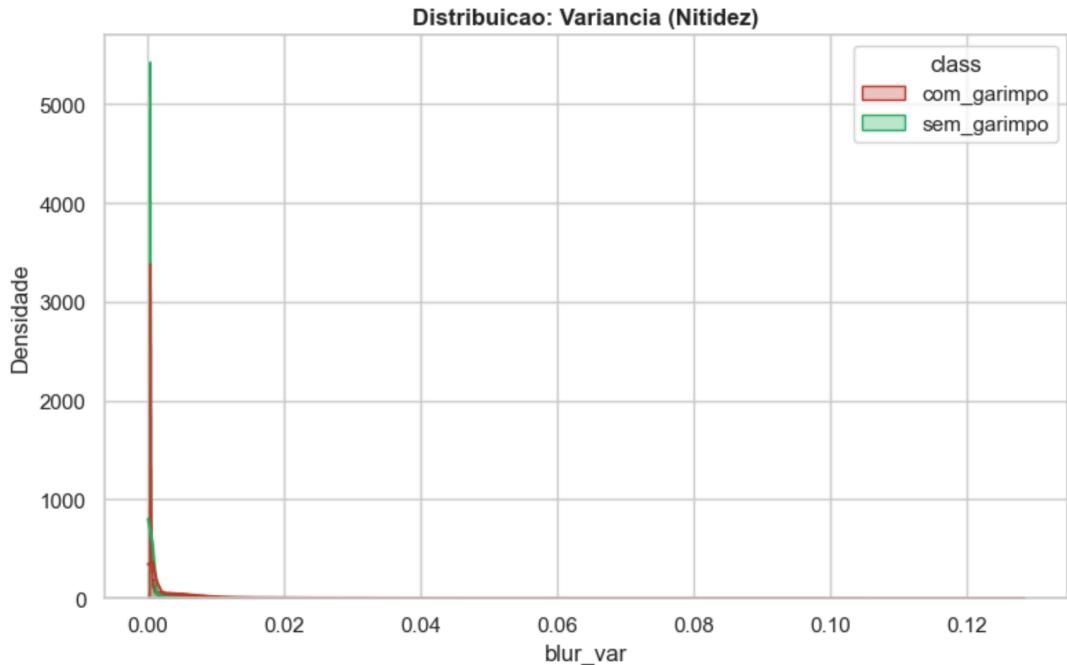
Figura 11 – Gráfico de Separabilidade do Índice de Vegetação (ExG).



Fonte: Própria

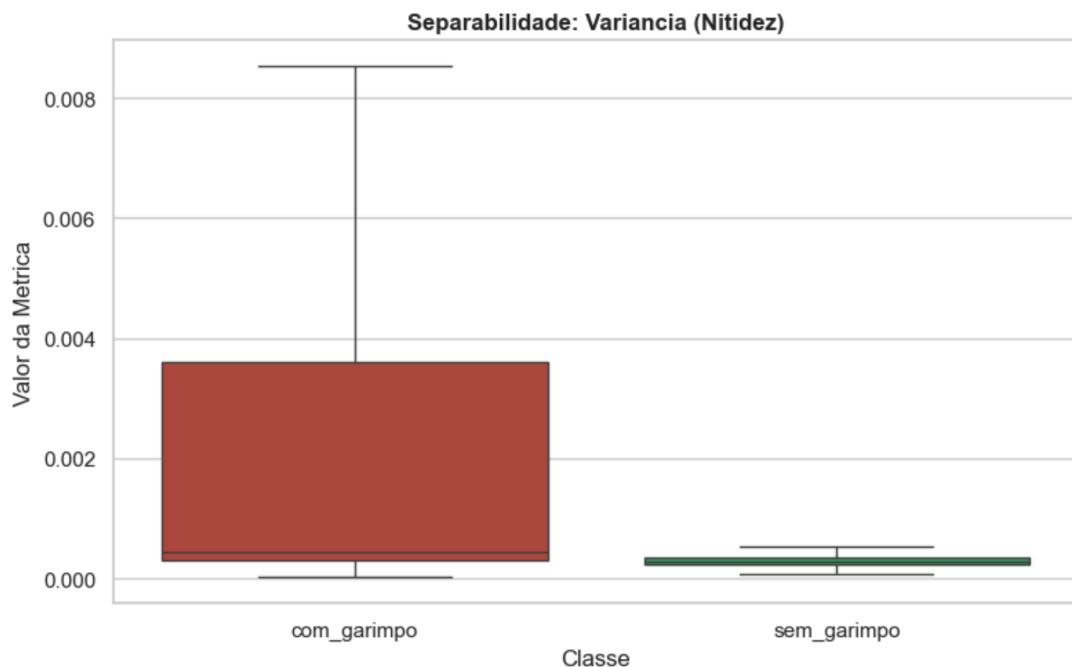
O resultado mais promissor surgiu na análise de textura, medida pela Variância do Laplaciano. A Figura 12 evidencia que as imagens de garimpo são significativamente mais "rugosas" e caóticas, ou seja, com maior variância (como mostrado na Figura 13) do que as imagens de controle, que tendem a ser mais homogêneas. A diferença relativa entre as médias das duas classes superou 120% para este atributo. Esse dado sugere que a textura é um discriminador forte, capturando a complexidade visual das cavas e do revolvimento da terra.

Figura 12 – Gráfico de Distribuição da Variância (Nitidez).



Fonte: Própria

Figura 13 – Gráfico de Separabilidade da Variância (Nitidez).

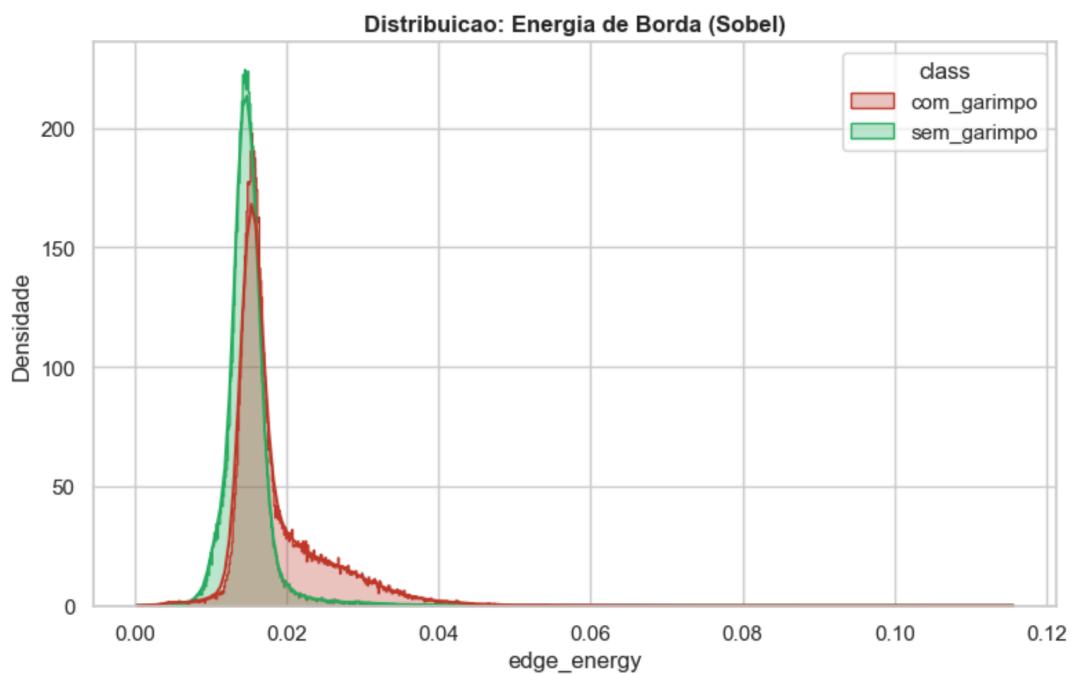


Fonte: Própria

Complementando a análise de textura, avaliou-se também a Energia de Borda, calculada através da aplicação do filtro Sobel sobre a matriz de intensidade dos pixels.

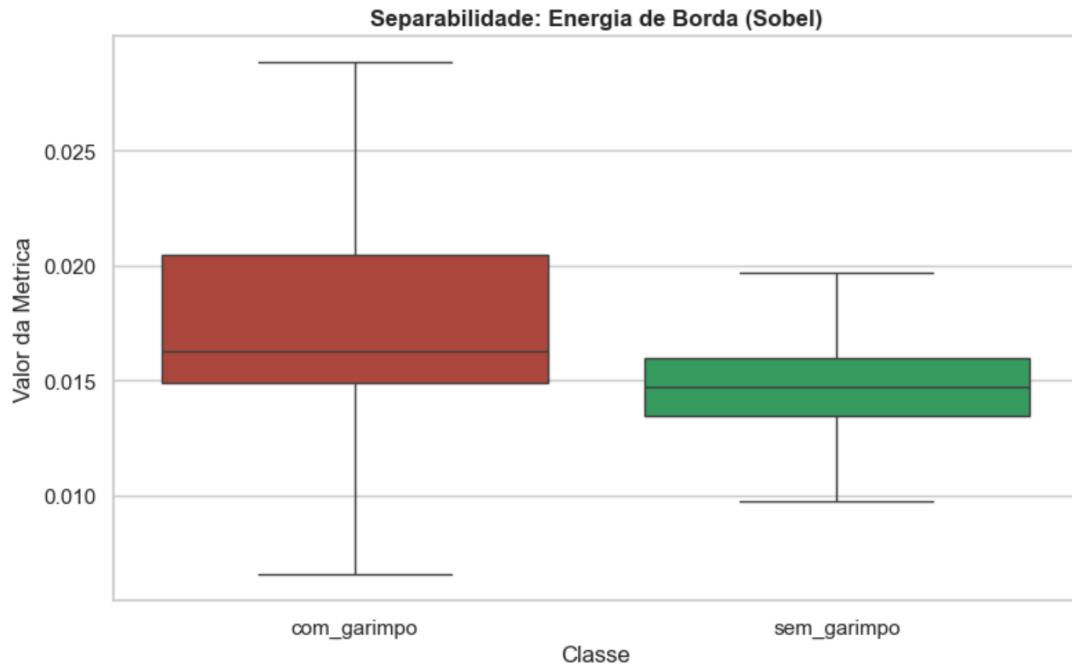
Conforme ilustrado na Figura 14 e na Figura 15, as áreas de garimpo apresentam valores significativamente mais elevados de energia se comparadas à classe negativa. Enquanto a floresta preservada tende a ter transições suaves de cor entre as copas das árvores, o garimpo é caracterizado por mudanças abruptas entre solo exposto, água e vegetação, gerando gradientes fortes. Esse resultado reforça a conclusão de que os atributos estruturais (formas e bordas) são tão ou mais importantes que a cor para distinguir as classes.

Figura 14 – Gráfico de Distribuição da Energia de Borda (*Sobel*).



Fonte: Própria

Figura 15 – Gráfico de Separabilidade da Energia de Borda (*Sobel*).

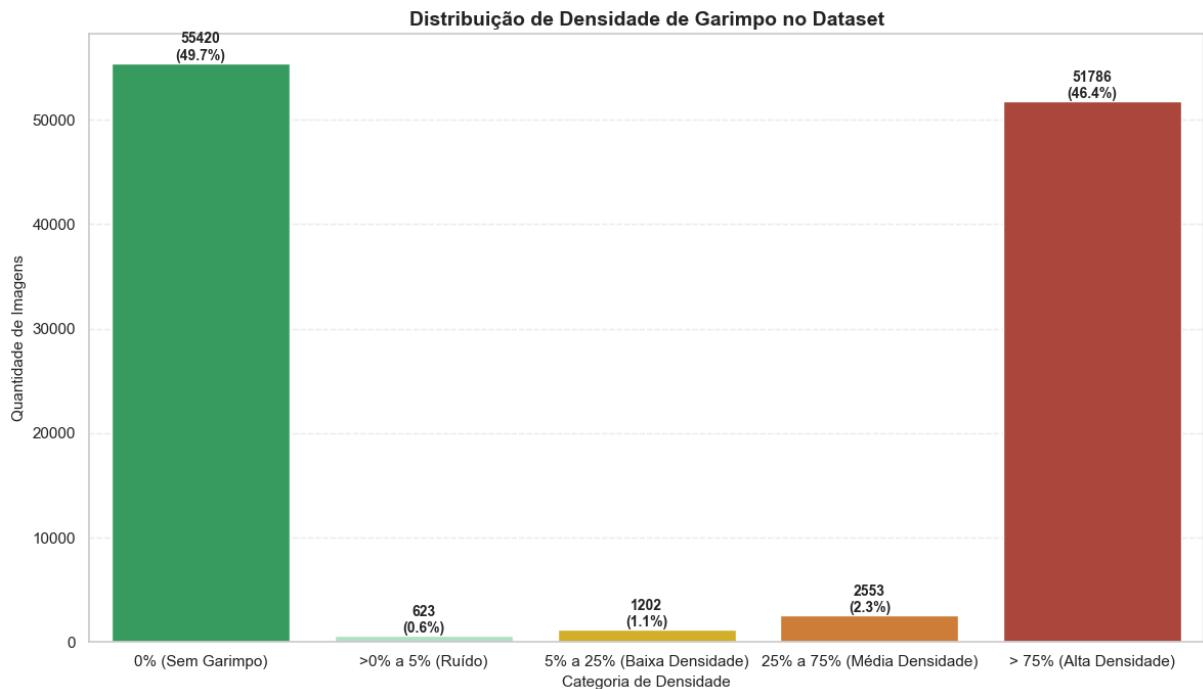


Fonte: Própria

Além dos atributos visuais, analisou-se a consistência semântica do *dataset* através da fração de área degradada (*overlap ratio*) em cada *chip*. O objetivo desta métrica foi compreender a distribuição dos exemplos positivos que serão apresentados à rede neural.

O gráfico de barras (Figura 16) revela a composição do conjunto de dados. Observa-se que a maioria das amostras positivas concentra-se na faixa de Alta Densidade ( $> 75\%$ ), totalizando mais de 51 mil imagens. Isso indica que o modelo terá uma base robusta de exemplos onde o padrão de garimpo é predominante na imagem.

Figura 16 – Gráfico de Barras da Distribuição de Densidade de Garimpo no *Dataset*.



Fonte: Própria

As outras faixas apresentam frequências significativamente menores: a categoria de Ruído ( $> 0\%$  a 5%) contém 623 imagens, enquanto a de Baixa Densidade (5% a 25%) conta com aproximadamente 1.200 amostras. Essa distribuição confirma que a maior parte dos recortes captura frentes de garimpo consolidadas, restando uma pequena parcela de exemplos de transição (bordas) ou com vestígios mais sutis.

Com a validação da qualidade dos dados e a identificação de atributos discriminantes (como textura e brilho), surge a questão fundamental: esses descriptores estatísticos simples são suficientes para automatizar a detecção com alta precisão? Para responder a isso e mensurar o ganho real trazido pelo Aprendizado Profundo, torna-se necessário testar até onde modelos tradicionais de Aprendizado de Máquina conseguem chegar utilizando apenas essas informações tabulares. Deste modo, a próxima seção dedica-se a estabelecer essa linha de base (*baseline*) com modelos de referência.

#### 4.4 Avaliação de *Baseline* com Algoritmos Clássicos de Aprendizado de Máquina

Antes de avançar para a implementação das Redes Neurais Convolucionais (CNNs), optou-se por estabelecer uma linha de base (*baseline*) de desempenho. O objetivo desta etapa consistiu em verificar se a detecção de garimpo poderia ser solucionada de maneira

satisfatória utilizando apenas descritores estatísticos globais (como brilho, textura e índices de vegetação) e algoritmos tradicionais, sem a necessidade de processamento profundo de imagens.

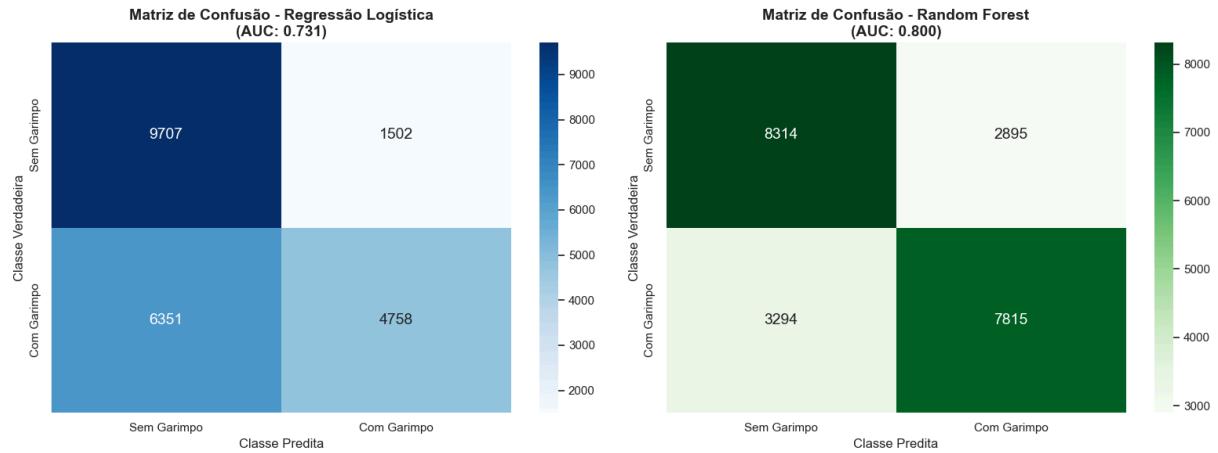
Para a execução dos experimentos, utilizou-se a biblioteca *scikit-learn* em linguagem Python. O vetor de características (*features*) foi composto por quatro descritores estatísticos extraídos de cada imagem: o índice de vegetação ExG (*exg\_mean*), o brilho médio (*brightness*), a energia de borda (*edge\_energy*) e a variância do Laplaciano como medida de nitidez (*blur\_var*). A variável alvo (*target*) consistiu na classificação binária das amostras, atribuindo-se o valor 0 para a classe “Sem Garimpo” e o valor 1 para a classe “Com Garimpo”, conforme rotulagem prévia. Ressalta-se que a divisão entre os conjuntos de treinamento e teste, definida no manifesto do *dataset*, foi rigorosamente respeitada, garantindo que os modelos não tivessem acesso aos dados de validação durante a fase de aprendizado. Então foram treinados dois algoritmos clássicos com abordagens distintas:

1. **Regressão Logística:** Escolhida para testar a linearidade do problema. Para este modelo, aplicou-se a normalização dos dados (*StandardScaler*), visto que algoritmos baseados em gradiente são sensíveis à escala das variáveis.
2. **Random Forest:** Selecionado por sua capacidade de modelar fronteiras de decisão não-lineares. O modelo foi configurado com 100 árvores de decisão, permitindo capturar regras de classificação mais complexas a partir dos atributos brutos.

#### 4.4.1 Matrizes de Confusão e Métricas

A avaliação do desempenho iniciou-se pela análise visual das matrizes de confusão, apresentadas na Figura 17. Essa ferramenta permite identificar não apenas o erro global, mas o comportamento específico do modelo para cada classe.

Figura 17 – Matrizes de Confusão da Regressão Logística e do *Random Forest* no *Baseline*.



Fonte: Própria

Ao observar a matriz da Regressão Logística (à esquerda), nota-se uma dispersão crítica dos resultados. O modelo classificou erroneamente uma grande parcela das imagens de garimpo como "Sem Garimpo" (Falsos Negativos). Esse comportamento indica que, para um classificador linear, as características visuais das áreas degradadas se confundem facilmente com o fundo, resultando em uma baixa sensibilidade.

Já na matriz do *Random Forest* (à direita), observa-se uma concentração maior de previsões na diagonal principal, o que indica acertos. Houve uma redução expressiva tanto nos falsos negativos quanto nos falsos positivos. Isso sugere que a estrutura de decisão não-linear das árvores conseguiu isolar melhor os padrões de textura e borda que caracterizam o garimpo, embora ainda persista uma margem de erro relevante.

Para quantificar essas observações, consolidaram-se os resultados na Tabela 3, que apresenta as métricas de precisão, revocação (*recall*), *F1-Score* e AUC para ambos os algoritmos.

Tabela 3 – Métricas dos algoritmos de Regressão Logística e *Random Forest* na *Baseline*.

Modelo	Classe	Precisão	Revocação	F1-Score	Acurácia Global	AUC
Regressão Logística	Sem Garimpo	0,6	0,87	0,71	<b>0,65</b>	<b>0,73</b>
	Com Garimpo	0,76	<b>0,43</b>	0,55		
Random Forest	Sem Garimpo	0,72	0,74	0,73	<b>0,72</b>	<b>0,8</b>
	Com Garimpo	0,73	<b>0,7</b>	0,72		

Fonte: Própria

A análise da Tabela 3 revela a fragilidade do modelo linear. A revocação de 0,43 para a classe "Com Garimpo" significa que a Regressão Logística falhou em detectar 57% das áreas degradadas presentes no teste. Em um cenário real de monitoramento, isso representaria uma taxa de omissão inaceitável.

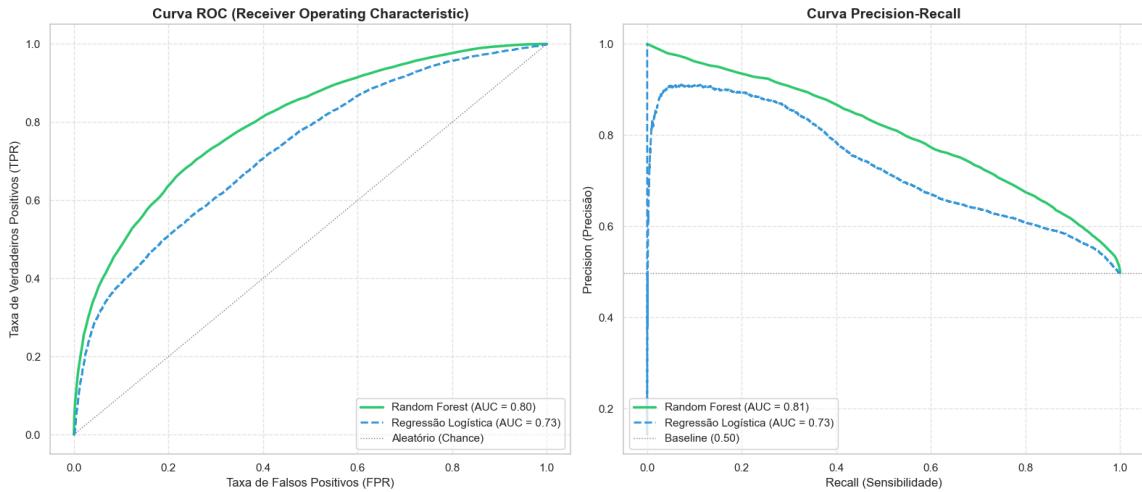
Entretanto, o *Random Forest*, por sua vez, apresentou um salto de qualidade. A revocação subiu para 0,70, equilibrada com uma precisão de 0,73. O *F1-Score* da classe alvo atingiu 0,72, demonstrando uma consistência muito maior. Contudo, a acurácia global de 72% e a AUC de 0,80 indicam que o modelo não atingiu um desempenho satisfatório. Cerca de 30% das amostras ainda são classificadas incorretamente, evidenciando que apenas os atributos estatísticos (sem a compreensão espacial da imagem) não são suficientes para resolver o problema com a robustez necessária.

#### **4.4.2 Curvas de Desempenho (ROC e Precision-Recall)**

Para uma análise independente do limiar de decisão, geraram-se as curvas ROC (*Receiver Operating Characteristic*) e *Precision-Recall*. Essas curvas permitem avaliar como o modelo se comporta ao variar a sensibilidade, o que é essencial para ajustar o equilíbrio entre falsos positivos e falsos negativos em um sistema de alerta real.

Conforme ilustrado na Figura 18, o Random Forest confirmou sua superioridade sobre o modelo linear, alcançando uma AUC (*Area Under the Curve*) de 0,80, enquanto a Regressão Logística obteve 0,73.

Figura 18 – Gráfico da Curva ROC e Curva *Precision-Recall* da Baseline.



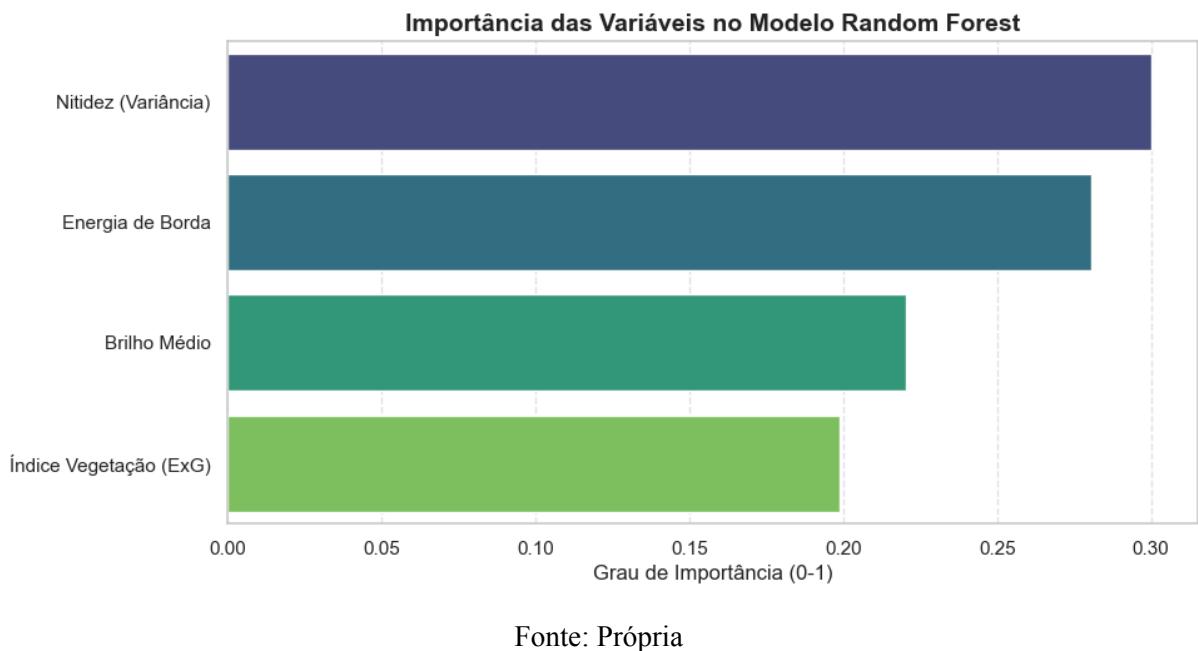
Fonte: Própria

A diferença de 0,07 na AUC reflete a capacidade do modelo não-linear de lidar melhor com a complexidade dos dados. Entretanto, o valor absoluto de 0,80 ainda indica uma separação imperfeita entre as classes. Em aplicações de monitoramento ambiental, onde a confiabilidade dos alertas é crucial, esse patamar de desempenho, combinado com uma acurácia de 72% (levantada na Tabela 3), costuma ser insuficiente, pois ainda implica em um volume considerável de erros, seja deixando passar garimpos reais ou gerando alertas falsos que desperdiçam recursos de fiscalização.

#### 4.4.3 Importância das Variáveis

A arquitetura do *Random Forest* oferece a vantagem de permitir a interpretabilidade, ou seja, permite mensurar a contribuição de cada atributo para a classificação final (*feature importance*). A Figura 19 apresenta o ranking das variáveis utilizadas no experimento.

Figura 19 – Gráfico de Importância das Variáveis na Classificação com *Random Forest*.



Os resultados obtidos e demonstrados na Figura 19, confirmam a avaliação das estatísticas observadas e avaliadas visualmente durante a etapa de Análise Exploratória de Dados (EDA), apresentadas na seção 4.3. Em que a Nitidez (Variância do Laplaciano) e a Energia de Borda se destacaram como os preditores mais relevantes, superando atributos de cor como o Brilho Médio e o índice de vegetação (ExG).

Com isso, essa hierarquia de importância permite inferir que, para o algoritmo, a "rugosidade" da textura e a presença de transições abruptas (bordas fortes) constituem sinais mais confiáveis para a detecção de garimpo do que apenas a resposta espectral do solo que envolve a avaliação das cores. Isso explica por que o modelo supera a Regressão Logística, que tenta separar as classes baseando-se mais na intensidade dos *pixels* do que propriamente na sua variação estrutural.

#### **4.4.4 Limitações do *Baseline* e Justificativa para Aprendizado Profundo**

Apesar de o Random Forest ter superado o modelo linear, o desempenho observado, com uma Acurácia de 72% e AUC de 0,80, revela as limitações intrínsecas das abordagens baseadas apenas em atributos tabulares, metadados e estatísticas globais.

Assim, a análise qualitativa dos erros mostra que o modelo tende a falhar sistematicamente em cenários de ambiguidade de textura. Por exemplo, pode-se dizer que

nuvens densas e texturizadas são frequentemente confundidas com garimpo gerando falsos positivos, enquanto áreas de mineração antigas ou visualmente homogêneas podem ser ignoradas, gerando falsos negativos.

Com isso, é possível concluir que essa barreira de desempenho ocorre porque o modelo processa a imagem como um conjunto de estatísticas, considerando média e variância, porém ignorando a geometria e o contexto espacial. Para o *Random Forest*, não há distinção entre a textura alta de uma nuvem e a de uma cava de mineração, pois ele não "enxerga" a forma. Tal constatação fundamenta a necessidade da utilização de Redes Neurais Convolucionais (CNNs), tema da próxima seção. Diferentemente dos métodos clássicos, as CNNs são capazes de extrair hierarquias de características espaciais, permitindo distinguir a morfologia específica das cicatrizes de mineração e superar as limitações observadas neste *baseline*.

#### **4.5 Detecção de Garimpo com Redes Neurais Convolucionais (CNNs)**

Uma vez demonstradas as limitações dos modelos baseados em atributos estatísticos globais, como a regressão logística ou o *Random Forest*, ficou visível que ambos não conseguem capturar a geometria e o contexto espacial das frentes de garimpo. Com isso, avançou-se para a implementação de Redes Neurais Convolucionais (CNNs), uma abordagem que se fundamenta na capacidade dessas redes de aprenderem, de forma hierárquica e automática, utilizando filtros espaciais que detectam desde bordas simples até padrões mais complexo (GOODFELLOW; BENGIO; COURVILLE, 2016), como no caso desta pesquisa, cavas, pistas de pouso e plumas de sedimentos.

Assim, nesta seção, detalham-se os experimentos realizados com duas arquiteturas distintas, primeiro uma rede convolucional simples, denominada *Simple CNN*, desenvolvida com o objetivo de validar o fluxo de treinamento, e a segunda uma EfficientNet-B0 (TAN; LE, 2019), uma arquitetura moderna utilizada via transferência de aprendizado (*Transfer Learning*). O objetivo central foi superar o desempenho de 72% de acurácia estabelecido pelo *baseline* na seção anterior, buscando uma solução robusta para o monitoramento de garimpo na Amazônia.

#### 4.5.1 Configuração Experimental e Pré-Processamento

Para viabilizar o treinamento profundo, o ambiente experimental foi configurado utilizando a biblioteca PyTorch, com aceleração de *hardware* provida por uma GPU NVIDIA GeForce RTX 4070 com 12 GB de VRAM, em um Desktop contendo um Ryzen 7 7700X (8 núcleos e 16 threads) e 32 GB de memória RAM DDR5 com 4800 MHz.

Diferentemente da etapa de *Machine Learning* clássico, o treinamento de redes neurais exige um conjunto de dados de validação para monitorar a convergência e evitar o *overfitting* (GOODFELLOW; BENGIO; COURVILLE, 2016). Para isso, realizou-se uma subdivisão interna no conjunto de treino original. Reservando 20% das amostras para validação mantendo o balanceamento das classes e resultando na distribuição final apresentada abaixo:

1. **Treino:** 71.412 imagens (utilizadas para ajuste dos pesos);
2. **Validação:** 17.854 imagens (utilizadas para ajuste de hiperparâmetros e *early stopping*);
3. **Teste:** 22.318 imagens (mantidas isoladas para a avaliação final).

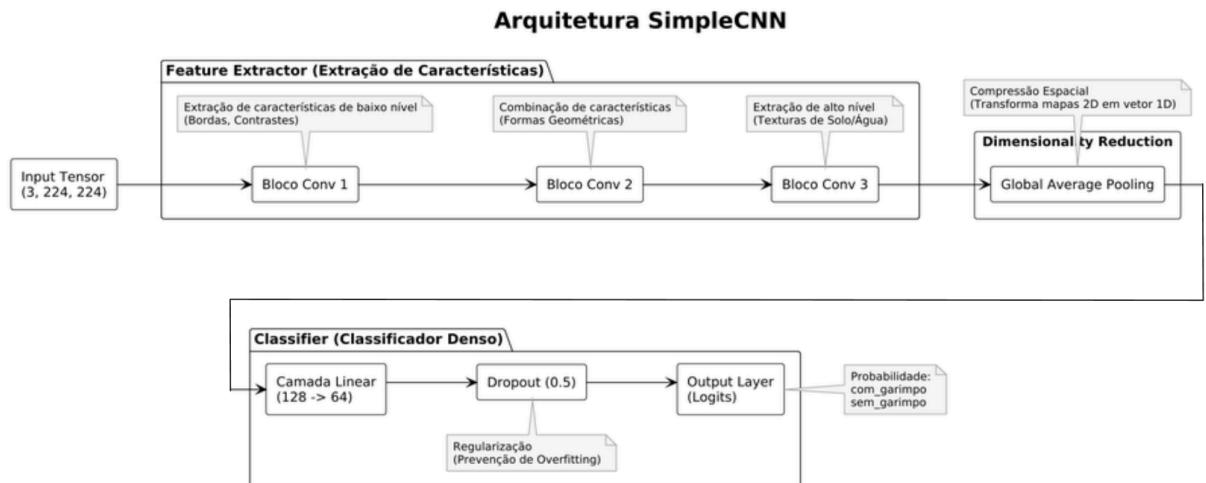
Assim, no pré-processamento dos dados, aplicaram-se duas transformações essenciais. A primeira foi o redimensionamento (*upsampling*) das imagens de 128x128 *pixels* para 224x224 *pixels*. Essa adaptação foi necessária para compatibilizar a entrada com a arquitetura EfficientNet, que foi pré-treinada nesta resolução espacial (TAN; LE, 2019). A segunda foi a aplicação de técnicas de *Data Augmentation* (aumento de dados) no conjunto de treino, incluindo rotações e espelhamentos aleatórios, uma estratégia que visa expor a rede a variações geométricas do mesmo alvo, aumentando sua capacidade de generalização e robustez.

#### 4.5.2 Arquiteturas Avaliadas

O estudo comparativo estruturou-se em torno de duas arquiteturas com níveis de complexidade distintos. A primeira, denominada Simple CNN, apresentada na Figura 20, consistiu em uma implementação personalizada composta por três camadas de convolução, projetadas para detectar bordas simples, formas geométricas e texturas, seguidas de operações de max-pooling e camadas totalmente conectadas. O propósito deste modelo foi estabelecer uma prova de conceito intermediária, verificando se uma rede neural rasa, treinada do zero

(*from scratch*), seria capaz de extrair características espaciais superiores aos descritores estatísticos utilizados anteriormente no *Random Forest*.

Figura 20 – Diagrama da Arquitetura da *Simple CNN*.

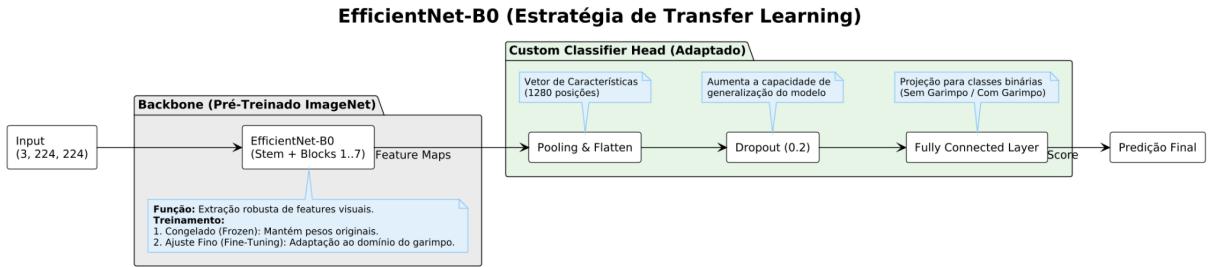


Fonte: Própria

Em contrapartida, a segunda abordagem (Figura 21) adotou a arquitetura EfficientNet-B0, proposta por Tan e Le, reconhecida pelo equilíbrio entre alta precisão e eficiência computacional. O treinamento utilizou a estratégia de Transferência de Aprendizado (*Transfer Learning*), partindo dos pesos pré-treinados na base de dados do ImageNet e seguindo duas fases distintas:

- **Fase 1 (Feature Extractor):** Inicialmente, realizou-se o congelamento dos pesos das camadas convolucionais (*backbone*), treinando apenas o classificador final. Essa etapa permitiu adaptar a rede ao problema binário (com garimpo vs sem garimpo), aproveitando os filtros visuais genéricos, capazes de identificar formas e contornos, já aprendidos pela rede em treinamentos anteriores com milhões de imagens.
- **Fase 2 (Fine-Tuning):** Na sequência, descongelaram-se todas as camadas para um ajuste fino com uma taxa de aprendizado reduzida. Esse processo permitiu que a rede especializasse seus filtros para as características singulares da Amazônia, aprendendo a distinguir nuances específicas como a textura da floresta tropical e a coloração turva dos rios impactados pela atividade garimpeira.

Figura 21 – Diagrama da EfficientNet-B0 via *Transfer Learning*.

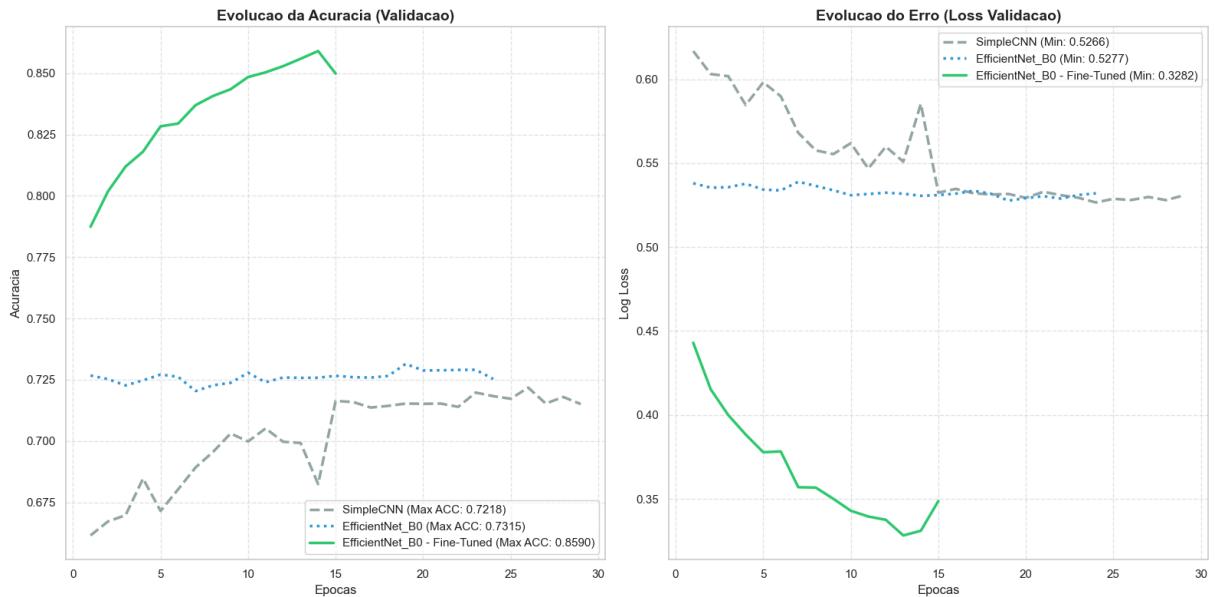


Fonte: Própria

#### 4.5.3 Dinâmica de Treinamento e Convergência

A análise das curvas de aprendizado permite compreender a estabilidade e a capacidade de generalização dos modelos avaliados ao longo das épocas. A Figura 22 apresenta o histórico consolidado do treinamento, exibindo à esquerda a evolução da acurácia e à direita a minimização da função de perda (*loss*).

Figura 22 – Gráficos de Histórico de Acurácia e *Loss*.



Fonte: Própria

Ao observar o gráfico de acurácia (Figura 22, esquerda), nota-se que a Simple CNN apresentou um aprendizado inicial rápido, mas estabilizou-se precocemente próximo à 15<sup>a</sup> época. O treinamento foi interrompido pelo mecanismo de *Early Stopping* na época 29, momento em que a rede atingiu uma estabilidade com aproximadamente 72% de acurácia.

Esse comportamento visual confirma que a arquitetura rasa encontrou um limite na sua capacidade de modelar os padrões complexos do garimpo, obtendo um desempenho semelhante ao do *baseline* estatístico.

Já as curvas referentes à EfficientNet-B0 ilustram claramente a eficácia da transferência de aprendizado em duas etapas. Na primeira fase (congelada), a rede convergiu rapidamente para um patamar de 73%, superando ligeiramente a rede simples. No entanto, o comportamento mais notável ocorre na fase de *Fine-Tuning*.

Conforme evidenciado no gráfico de *Loss* (Figura 22, direita), o descongelamento das camadas associado a uma taxa de aprendizado reduzida provocou uma queda abrupta na perda, rompendo a barreira de 0,50 e descendo para patamares inferiores a 0,35. Esse movimento reflete-se imediatamente na curva de acurácia, que saltou do patamar de 73% para 85,59%.

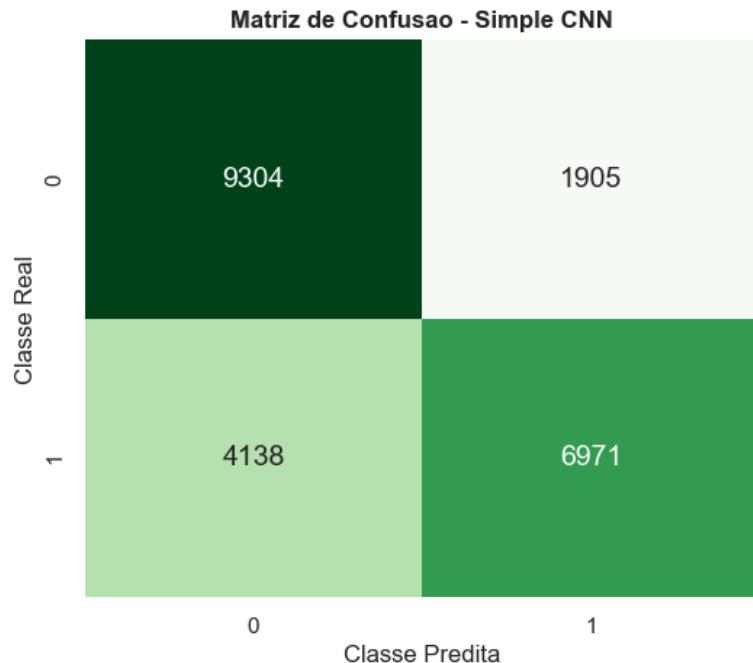
A correlação entre a diminuição consistente da perda de validação (*loss*) e o aumento da acurácia na fase final indica que o ajuste fino (*fine-tuning*) permitiu à rede aprender as "assinaturas visuais" exclusivas do garimpo amazônico, superando as ambiguidades que limitavam os modelos anteriores, sem apresentar sinais severos de *overfitting* (sobreajuste).

#### **4.5.4 Avaliação de Desempenho e Comparação Final**

A etapa final do experimento consistiu na avaliação quantitativa dos modelos aplicados sobre o conjunto de teste independente, que contém 22.318 imagens sendo 11.109 na classe "com\_garimpo" e 11.209 na classe "sem\_garimpo", consolidando os indicadores de generalização da abordagem proposta.

Inicialmente, foi analisada a matriz de confusão apresentada na Figura 23, que contém o desempenho da *Simple CNN* sobre o conjunto de teste, pode-se perceber que o comportamento observado foi muito semelhante ao do *baseline* com *Random Forest*. Nota-se ainda uma dispersão relevante de erros fora da diagonal principal, indicando dificuldade em separar classes com características visuais semelhantes.

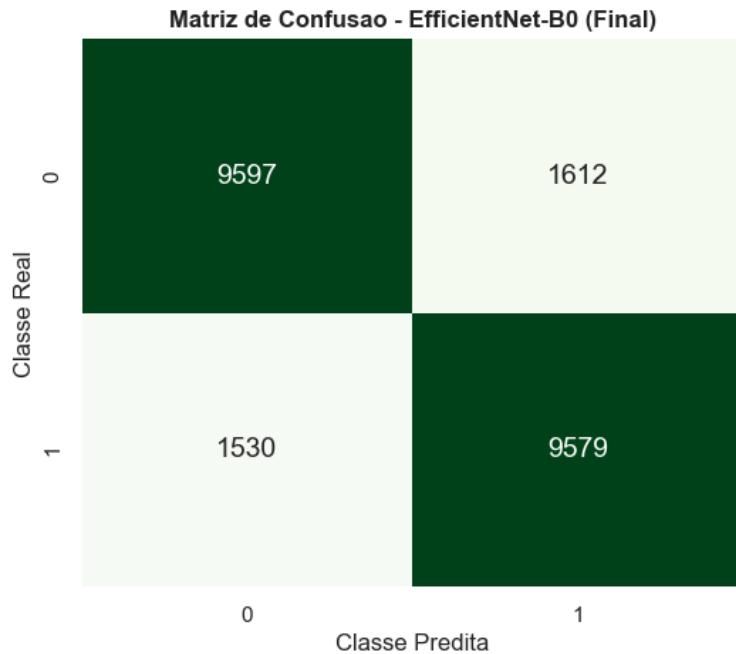
Figura 23 – Matriz de Confusão da *Simple CNN* sobre o Conjunto de Testes.



Fonte: Própria

Já a matriz de confusão da EfficientNet-B0 (*Fine-Tuned*) apresentada na Figura 24, demonstrou uma robustez superior, tal que houve uma redução drástica tanto nos falsos positivos quanto nos falsos negativos, resultando em uma concentração acentuada de acertos na diagonal principal.

Figura 24 – Matriz de Confusão da EfficientNet-B0 (*Fine-Tuned*) sobre o Conjunto de Testes.



Fonte: Própria

Por sua vez, a Tabela 4 sintetiza as métricas finais obtidas e calculadas após a inferência de ambos os modelos sobre o conjunto de testes, permitindo uma comparação direta entre a abordagem rasa e a abordagem baseada em transferência de aprendizado.

Tabela 4 – Métricas dos algoritmos de CNN: *Simple CNN* e EfficientNet-B0 (*Fine-Tuned*).

Modelo	Acurácia	AUC	F1-Score (Macro)	Precisão	Revocação
<b>Simple CNN</b>	0,73	0,81	0,73	0,74	0,73
<b>EfficientNet-B0 (Fine-Tuned)</b>	0,86	0,94	0,86	0,86	0,86

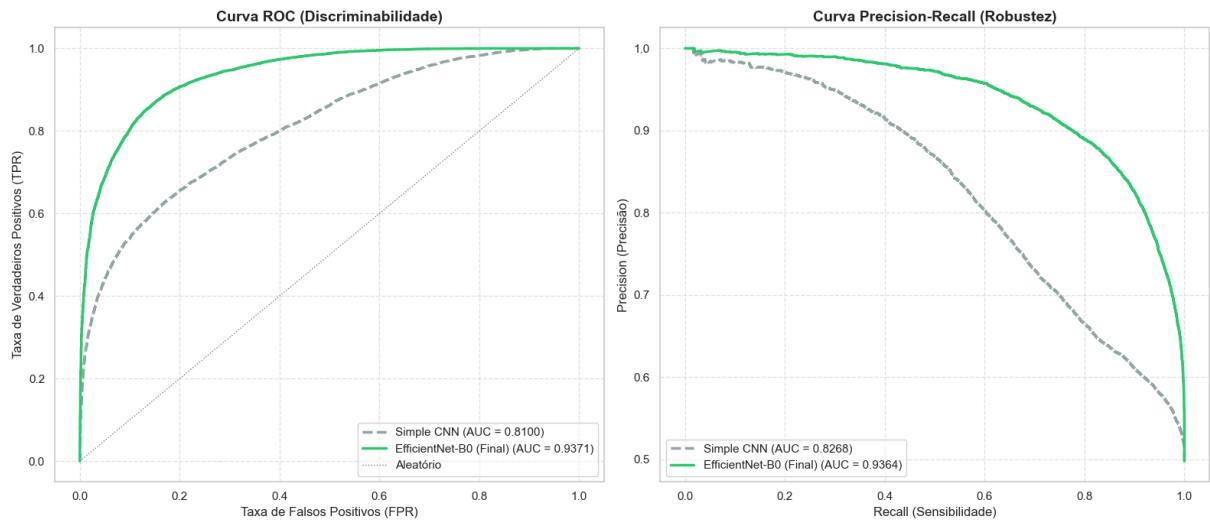
Fonte: Própria

Os dados revelam que a *Simple CNN* atingiu uma acurácia de aproximadamente 73% e uma AUC de 0,81, resultados estatisticamente equivalentes aos do *Random Forest* com uma Acurácia de 72% e AUC de 0,80. Isso sugere que uma arquitetura convolucional simples, treinada do zero, não consegue extrair características espaciais significativamente melhores do que os descritores de textura utilizados nos modelos clássicos.

Por outro lado, a EfficientNet-B0 (*Fine-Tuned*) proporcionou um salto qualitativo evidente. A acurácia global elevou-se para 85,92%, representando um ganho de

aproximadamente 13 pontos percentuais sobre as abordagens anteriores. Ainda mais relevante para aplicações de monitoramento é o indicador AUC (*Area Under the Curve*), que atingiu 0,9371, conforme demonstrado no gráfico da Figura 25. Esse valor próximo a 1,0 indica que o modelo possui uma excelente capacidade de discriminação, mantendo altas taxas de acerto independentemente do limiar de classificação escolhido.

Figura 25 – Gráfico das Curvas ROC Comparativas entre os modelos *Simple CNN* e *EfficientNet-B0 (Fine-Tuned)*.



Fonte: Própria

Em suma, os resultados confirmam a hipótese deste trabalho: enquanto os modelos rasos e estatísticos estagnam na casa dos 72-73% devido à complexidade visual do cenário amazônico, o uso de Redes Neurais Convolucionais profundas, aliadas a técnicas de *Fine-Tuning*, é capaz de capturar a hierarquia espacial e semântica necessária para elevar a precisão do monitoramento a um patamar operacionalmente viável.

#### 4.6 Reprodutibilidade e Disponibilização de Recursos

Com o objetivo de garantir a transparência do trabalho e permitir a reprodutibilidade de todas as etapas metodológicas, todo o código-fonte desenvolvido foi documentado e disponibilizado em repositório público.

O material pode ser acessado na plataforma GitHub através do endereço: [https://github.com/leonardogrupioni/TCC\\_CNN\\_Garimpo\\_Amazonia](https://github.com/leonardogrupioni/TCC_CNN_Garimpo_Amazonia). A organização do repositório reflete o fluxo apresentado neste capítulo, incluindo:

- O *script* em JavaScript para coleta e tratamento inicial das imagens no Google Earth Engine;
- As rotinas em Python para geração dos recortes (*chips*), rotulagem e divisão dos dados;
- Os notebooks com a Análise Exploratória de Dados (EDA) e os testes com os modelos de *baseline*;
- Os códigos completos de configuração, treinamento e validação das Redes Neurais Convolucionais (*Simple CNN* e EfficientNet-B0).

Além disso, considera-se a publicação futura do *dataset* em repositórios de dados científicos (como Zenodo ou Kaggle) para a obtenção de um identificador digital (DOI). Essa iniciativa busca facilitar o acesso a dados rotulados de garimpo, contribuindo para que outros estudantes e pesquisadores possam desenvolver novos estudos sobre o monitoramento da Amazônia.

## 5. CONCLUSÃO

O presente trabalho atingiu seu objetivo principal ao desenvolver e validar um modelo de visão computacional baseado em Redes Neurais Convolucionais (CNNs) capaz de identificar frentes de garimpo ilegal na Amazônia com precisão.

A jornada metodológica iniciou-se pela constatação de que métodos tradicionais de sensoriamento remoto enfrentam barreiras significativas na região. A Análise Exploratória de Dados (EDA) e os experimentos com modelos de *baseline* demonstraram que descritores estatísticos simples, como alterações na cor do solo ou índices de vegetação, são insuficientes para capturar a complexidade do problema. No qual, o modelo *Random Forest*, limitado a uma acurácia de 72% e uma AUC de 0,80, comprovou que a detecção de garimpo não é um problema linearmente separável e que a falta de contexto espacial leva a confusões frequentes entre nuvens, plumas de sedimento e áreas degradadas.

A implementação da arquitetura EfficientNet-B0, aliada à estratégia de Transferência de Aprendizado e *Fine-Tuning*, representou o ponto de inflexão da pesquisa. Ao permitir que a rede aprendesse hierarquias visuais específicas (como a geometria das cavas e a textura das plumas de sedimentos) foi possível elevar a acurácia para 85,92% e a área sob a curva ROC (AUC-ROC) para 0,9371. Esses resultados confirmam a hipótese de que o Aprendizado Profundo é uma ferramenta indispensável para superar os ruídos e ambiguidades inerentes ao monitoramento orbital na Amazônia.

Além dos indicadores de desempenho, este estudo entrega contribuições práticas relevantes, como um fluxo de coleta de dados reproduzível no Google Earth Engine, um dataset com mais de 111 mil recortes rotulados e um repositório de código aberto. Esses recursos fornecem uma base técnica sólida, permitindo que outros pesquisadores reproduzam os experimentos e avancem no desenvolvimento de sistemas de triagem automática.

Por fim, este estudo evidencia que a Ciência da Computação tem um papel prático a desempenhar na preservação do meio ambiente, servindo como um poderoso meio para potencializar a fiscalização ambiental. Ao comprovar que algoritmos podem aprender a identificar cicatrizes de mineração com precisão, abre-se caminho para um monitoramento mais ágil, onde a inteligência artificial atua filtrando e classificando grandes volumes de dados, permitindo que as ações de proteção da floresta sejam mais rápidas, precisas e efetivas.

## 5.1 Trabalhos Futuros

Apesar dos resultados promissores obtidos com a classificação binária em imagens estáticas, o desenvolvimento deste trabalho evidenciou desafios e oportunidades que abrem frentes para novas investigações. Sugerem-se as seguintes direções para a continuidade e expansão da pesquisa:

- **Expansão para Detecção Multiclasse:** O modelo atual limita-se à distinção entre "garimpo" e "não garimpo". Trabalhos futuros podem evoluir para uma abordagem multi-classe, capaz de categorizar simultaneamente diferentes tipos de impactos ambientais, como desmatamento por corte raso, queimadas, degradação florestal e garimpo. Essa granularidade permitiria um diagnóstico mais completo das ameaças ao bioma.
- **Análise Temporal com Séries Históricas:** A implementação de redes neurais recorrentes (como LSTMs) ou arquiteturas baseadas em atenção (*Transformers*) aplicadas a séries temporais de imagens (ex: coleção histórica Landsat ou Sentinel-2) permitiria analisar a dinâmica de evolução do uso do solo. Isso facilitaria a distinção entre bancos de areia naturais, que possuem ciclos sazonais definidos, e frentes de garimpo, que apresentam padrões de expansão progressiva e irregular.
- **Sistemas Embarcados e Monitoramento com VANTS:** Uma perspectiva ambiciosa e de alto valor prático reside no desenvolvimento de sistemas de detecção embarcados em Veículos Aéreos Não Tripulados (VANTS/Drones). A portabilidade de modelos compactados para hardware de borda (*Edge Computing*) permitiria a realização de inferências in loco e em baixa altitude, superando a barreira de nuvens que limita os satélites e oferecendo uma ferramenta tática de apoio direto às equipes de fiscalização em campo.

A concretização dessas propostas permitirá não apenas a evolução técnica do modelo aqui apresentado, mas também a consolidação de um sistema de inteligência computacional robusto, capaz de operar em diversos cenários e oferecer respostas à altura da urgência que a preservação da Amazônia exige.

## REFERÊNCIAS

- ARCANJO, J. S. ; et al.** A multi-source WFI datacube of CBERS-4 and CBERS-4A images: Improving visual interpretation. In: XX Brazilian Symposium on Remote Sensing (SBSR) 2023, 2023, Florianópolis. Proceeding of the XX Brazilian Symposium on Remote Sensing (SBSR), 2023
- BREIMAN, L.** Random forests. Machine Learning, 2001.
- BUDA, M.; MAKI, A.; MAZUROWSKI, M.** A systematic study of the class-imbalance problem in convolutional neural networks. Neural Networks, 2018.
- CAMALAN, S.; RUI, Y.; ZHANG, C.** Change detection of Amazonian alluvial gold mining using deep learning and Sentinel-2 imagery. Remote Sensing, 2022.
- CORTES, C.; VAPNIK, V.** Support-vector networks. Machine Learning, 1995.
- CUTRIM DOS SANTOS, P. T.** Aprimoramento da detecção de áreas de garimpo na região do Tapajós através de redes adversárias de super-resolução. São Luís: UFMA, 2021. Monografia (Bacharelado em Ciência da Computação).
- ESA.** Sentinel-1 SAR Technical Guide. Paris, 2022.
- ESA.** Sentinel-2 User Handbook. Paris, 2023.
- GALLWEY, B.; MOLINARIO, G.; et al.** A Sentinel-2 based multispectral convolutional neural network for detecting artisanal small-scale mining in Ghana. Pre-print, 2020.
- GLOBAL CLOUD BIAS IN OPTICAL SATELLITE REMOTE SENSING OF RIVERS.** Geophysical Research Letters, e2024GL110085, 2024.
- GLOBAL INITIATIVE AGAINST TRANSNATIONAL ORGANIZED CRIME.** Amazon underworld: economias criminosas na maior floresta tropical do mundo. Genebra: GI-TOC; Amazon Watch; InfoAmazonia, 2023.

**GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A.** Deep learning. Cambridge: MIT Press, 2016.

**GOOGLE EARTH ENGINE.** Forest cover and loss estimation – Developer tutorial. Mountain View, 2025. Disponível em:  
<https://developers.google.com/earth-engine/tutorials/community/forest-cover-loss-estimation>. Acesso em: 10 mai. 2025.

**GORELICK, N.; HANCHER, M.; DIXON, M.; et al.** Google Earth Engine: planetary-scale geospatial analysis for everyone. Remote Sensing of Environment, 2017.

**GUTERRES, A.** Post na rede social X (antigo Twitter). 23 ago. 2019. Disponível em:  
<https://x.com/antoniooguterres/status/1164586391629705216>. Acesso em: 10 mai. 2025.

**HAYKIN, S.** Neural networks and learning machines. 3. ed. Upper Saddle River: Pearson, 2009.

**INPE.** Missão Amazônia-1: especificações técnicas. São José dos Campos, 2021.

**INPE.** Sistema DETER – Detecção de Desmatamento em Tempo Real, São José dos Campos, 2024. Disponível em: <https://www.obt.inpe.br/OBT/assuntos/programas/amazonia/deter>. Acesso em: 10 mai. 2025.

**INSTITUTO IGARAPÉ.** O ecossistema do crime ambiental na Amazônia. Rio de Janeiro, 2021.

**LIMA, L. C. R.** Mapeamento das áreas de garimpo em terras indígenas Munduruku utilizando modelo baseado em conhecimento e integração multisensores. 2022. Trabalho de Conclusão de Curso (Engenharia Cartográfica e Agrimensura) – Instituto Federal de Goiás, Goiânia, 2022.

**LOBO, F. D. L.; SOUZA-FILHO, P. W. M.; NOVO, E. M. L. M.** Mapping mining areas in the Brazilian Amazon using MSI/Sentinel-2 imagery. Remote Sensing, 2018.

**MAPBIOMAS.** Amazônia concentra mais de 90% do garimpo no Brasil. 22 set. 2025. Disponível em:

<https://brasil.mapbiomas.org/2023/09/22/amazonia-concentra-mais-de-90-do-garimpo-no-brasil/>. Acesso em: 10 mai. 2025.

**MAPBIOMAS.** Coleção 9 – Área ocupada pela mineração no Brasil. São Paulo, 2023. Disponível em: <https://brasil.mapbiomas.org/map/colecao-9/>. Acesso em: 10 mai. 2025.

**MAPBIOMAS.** ATBD Collection 8: metodologia de processamento no Google Earth Engine. São Paulo: MapBiomas, 2025. Disponível em:

<https://brasil.mapbiomas.org/wp-content/uploads/sites/4/2023/08/Cerrado-Appendix-ATBD-Collection-8.pdf>. Acesso em: 01 jun. 2025.

**MINISTÉRIO PÚBLICO FEDERAL.** Mineração ilegal de ouro na Amazônia: marcos jurídicos e questões controversas. Brasília, 2020.

**MOLINA, L. P. (org.).** Terra rasgada: como avança o garimpo na Amazônia brasileira. Brasília: Aliança em Defesa dos Territórios, 2023.

**NASA.** GEDI Level 2A Footprint User Guide. Greenbelt: Goddard Space Flight Center, 2021.

**NOVO, E. M. L. M.** Sensoriamento remoto: princípios e aplicações. 4. ed. São Paulo: Edgard Blücher, 2010.

**RAISG – Rede Amazônica de Informação Socioambiental Georreferenciada.** Illegal mining shapefiles, 2025.

**RODRIGUES, L. P. S.** Inteligência artificial para analisar o desmatamento na região Amazônica brasileira. Porto: Universidade do Porto, 2024. Tese (Doutorado).

**SELVARAJU, R. R.; COGSWELL, M.; DAS, A.; VEDANTAM, R.; PARIKH, D.; BATRA, D.** Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based

Localization. In: IEEE International Conference on Computer Vision (ICCV), 2017, Venice. Proceedings... Venice: IEEE, 2017. p. 618–626. DOI: 10.1109/ICCV.2017.74.

**SENTINEL HUB.** s2cloudless – machine-learning cloud detector for Sentinel-2 imagery, 2024. Disponível em:

<https://docs.sentinel-hub.com/api/latest/user-guides/cloud-masks/#cloud-masks-and-cloud-probabilities>. Acesso em: 10 mai. 2025

**SHIMABUKURO, Y. E.; PONZONI, F. J.** Sensoriamento remoto no estudo da vegetação. São José dos Campos: Parêntese, 2007.

**SOKOLOVA, M.; LAPALME, G.** A systematic performance evaluation of classification algorithms for imbalanced data. *Information Processing & Management*, 2009.

**SUNDARARAJAN, M.; TALIYAN, A.; YAN, Q.** Axiomatic attribution for deep networks. In: Proceedings of the 34th International Conference on Machine Learning, 2017.

**TAN, M.; LE, Q. V.** EfficientNet: rethinking model scaling for convolutional neural networks. In: International Conference on Machine Learning. PMLR, 2019.

**TORRES, D. L.; et al.** Deforestation detection with fully convolutional networks in the Amazon forest from Landsat-8 and Sentinel-2 images. *Remote Sensing*, 2021.

**USGS – U.S. Geological Survey.** Fifty years of Landsat: observing Earth to look forward. 2022. Disponível em:

<https://www.usgs.gov/news/featured-story/fifty-years-landsat-observing-earth-look-forward>. Acesso em: 10 jun. 2025

**ZHU, Z.; WOODCOCK, C. E.** Fmask 4.0: improved cloud and cloud-shadow detection in Landsat and Sentinel-2 images. *Remote Sensing of Environment*, 2019.